




Tipos de medidas resumen

Las **medidas de resumen** sirven para sintetizar las características dominantes del conjunto de datos, mediante el cálculo de unas cifras que sean representativas de la muestra o de la población. Recuerda que la **población** es el **conjunto total** de los datos en una situación específica, el cual no siempre es posible analizar por completo. Debido a esto, podemos seleccionar un **subconjunto** de la población conocido como **muestra**, y a partir de ella se estiman los valores poblacionales.


Quizás escucharás los términos de **parámetro y estadístico** al realizar este tipo de análisis; por lo que es necesario que conozcas la diferencia entre uno y otro.

- **Parámetro:** representa una medida que describe el comportamiento de los datos poblacionales; se representan con **letras griegas** tales como μ (llamada **miu**) y σ (conocida como **sigma**).
- **Estadístico:** representa una medida que describe el comportamiento de los datos muestrales, para los cuales se utilizan letras latinas como $\bar{x}$ (denominada **equis testada**) y s (**ese, que describe la desviación estándar en la muestra**), entre otras.

Las medidas resumen se clasifican en tres tipos: las de **tendencia central**, las de **dispersión** y las de **forma**.





Veamos una imagen para ilustrar mejor esta clasificación:



Cómo elegir la mejor medida de tendencia central:

- **Moda** – Cuando los datos **no son numéricos**.
- **Mediana** – Cuando **existe un valor atípico**.
- **Media** – Cuando **no hay valores atípicos** o la posibilidad de que existan es muy baja.



Medidas de tendencia central

Las **medidas de tendencia central** son medidas que suelen ubicarse en el centro de los datos y nos indican el punto medio o **valor típico** de los datos. Se les llama así porque, generalmente, la acumulación más alta de datos se encuentra en los valores intermedios, además de ser medidas que nos ayudan a saber dónde están los datos, pero sin indicar cómo se distribuyen.

Si bien la media aritmética es la más conocida, existen otras como la media ponderada, la media geométrica, la mediana (o segundo cuartil) y la moda. **Las medidas de tendencia central más utilizadas y en las que nos enfocaremos son: media, mediana y moda.**

Imagina que una empresa tiene una campaña publicitaria digital, y ha obtenido los siguientes datos de la primera semana de circulación:

Día	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
Visitas	22	21	12	10	25	25	25

Veamos cuáles serían las medidas de tendencia central de este ejemplo.

1. Media aritmética

Es el promedio. Se representa como μ (miu) cuando es la media de la población y como $\bar{x}$ (equis testada) cuando es la media de la muestra.

En nuestro ejemplo, la media de visitas es de 20 diarias, esto implica que algunas veces hay valores menores y otras, mayores a 20.

A continuación, veremos las **propiedades de la media aritmética**, tanto su representación matemática como su significado en términos prácticos.

- **La suma de las desviaciones de los valores o datos, respecto a su medida aritmética es cero.**

$$\sum_{i=1}^n (x - \bar{x}) = 0$$

Esto significa que **es el centro de gravedad o el equilibrio** de toda distribución, y que representa a todos los valores observados.

- **La suma de los cuadrados de las desviaciones de los valores o datos, respecto a su media aritmética es un valor mínimo.**

$$\sum_{i=1}^n (x - \bar{x})^2 = \text{Valor mínimo}$$

Esto significa que ninguna otra cantidad (o dato) del conjunto de datos dará una cantidad menor a la que proporciona la media. **De esta propiedad surge el concepto de la varianza, y de la desviación estándar.**

2. Mediana

También es conocida como **percentil 50 o segundo cuartil**. Es una medida de orden, por lo que será necesario organizar los datos de menor a mayor para calcularla. Es el punto central de la distribución, es decir, es el valor tal que, la mitad de los datos de la distribución son menores a ella y la otra mitad son mayores.

La siguiente tabla muestra las visitas ordenadas de menor a mayor:

Día	Jueves	Miércoles	Martes	Lunes	Viernes	Sábado	Domingo
Visitas	10	12	21	22	25	25	25

En nuestro ejemplo la mediana de visitas es de 22 diarias. Lo que indica que el 50 % del tiempo ocurren 22 visitas o menos y el otro 50 %, 22 visitas o más.

3. Moda

Valor con mayor frecuencia, o el que más se repite, en la distribución de datos.

Cuando existen dos valores que tienen más frecuencia que el resto de los datos, se dice que la distribución de datos es **bimodal**. Si se tienen más de dos valores modales, la distribución es **multimodal** y **la moda pierde representatividad**. Si todos los valores ocurren con la misma frecuencia se dice que **no existe moda**.

En nuestro ejemplo la moda de visitas es de 25 diarias. Pues es el valor qué más se repite (3 veces).

Ahora, veamos cuáles son las ventajas e inconvenientes de cada una de las medidas de tendencia central:

	Ventajas	Inconvenientes
Media aritmética	• La media aritmética viene expresada en las mismas unidades que la variable. • Todos los valores de la distribución tienen la misma importancia. • Es única. • En su cálculo intervienen todos los valores de la distribución. • Es el centro de gravedad de toda distribución, representando a todos los valores observados.	• No puede ser utilizada en datos cualitativos. • Su principal inconveniente es que se ve afectada por los valores extremadamente grandes o pequeños de la distribución.
Mediana	• Es fácil de calcular. • Es la medida más representativa en el caso de variables que sólo admiten la escala ordinal. • En la mediana sólo influyen los valores centrales y es insensible a los valores atípicos (extremos) u "outliers".	• En su determinación no intervienen todos los valores de la variable.

Moda

- Es fácil de calcular.
- Es la medida más representativa en el caso de variables que sólo admiten la escala nominal.
- Es muy frecuente que todos los datos sean valores diferentes y ahí no hay moda.
- Se enfoca en el valor de mayor frecuencia e ignora al resto de los datos.
- Puede haber más de una moda (sugiere la existencia de varias poblaciones).

Ahora que conoces esta información, imagina que, en el departamento de telemarketing de tu negocio, registras las llamadas de quejas realizadas por tus clientes durante el último mes. Al calcular los promedios, el reporte muestra que por la mañana se reciben en promedio 30 llamadas y por la tarde solo 10. Esta información de tendencia central es muy útil para planear turnos, asignar personal o ajustar horarios de atención.

Sin embargo, ¿basta con conocer únicamente los promedios para tomar decisiones realmente sólidas? Para saber si las llamadas se concentran cerca de esos valores o si varían de manera importante, necesitamos ir más allá y analizar la dispersión de los datos. Ese será nuestro siguiente paso: **conocer las medidas de dispersión**.

| Medidas de dispersión

Una empresa de marketing ha decidido lanzar tres campañas como prueba piloto en preparación para las campañas navideñas. Cada una de ellas se realizará con un proveedor de *hosting* distinto, con el objetivo de evaluar cual es más confiable. ¿Qué criterio deberían de utilizar para determinar la confiabilidad de cada proveedor?

Quizá el primer impulso sería analizar el tiempo promedio de carga de las páginas de cada uno. Sin embargo, podríamos estar ignorando el hecho de que algunos proveedores tengan, en algunos momentos, tiempos muy lentos que se estén compensando con otros de muy buena velocidad, por lo que el promedio pudiera no ser un indicador confiable.

En este tipo de situaciones, sería recomendable que utilices medidas de dispersión para complementar tu análisis, ya que, si bien es importante conocer la media, el conocer la dispersión de los valores alrededor de ella te permitirá tener un panorama más claro de qué tan confiable es la medida de tendencia central.

La **dispersión (o variación)** es **el grado en que los datos numéricos tienden a extenderse alrededor de un valor medio, mostrando qué tan parecidos, o no, son los datos entre sí**. Según sea el entorno o la situación en la que se está utilizando la dispersión, esta reflejará **calidad, riesgo, consistencia, eficiencia**, entre otros. Esto nos lleva a la necesidad de plantearnos siempre la pregunta: ¿En este caso, qué refleja la variabilidad?

Para ilustrar la aplicación de estos conceptos, veamos un ejemplo:

Recuerda tu infancia... ¿Te sabes el nombre de los tres cochinitos? De seguro estás cantando la canción mentalmente tratando de recordarlos. En la versión en español no se mencionan por nombre, sin embargo, existen otras versiones en las que se conocen como Práctico, Violinista y Flautista, así que usaremos esos.

Imagina que los tres cochinitos fueron sometidos a una evaluación completa en su lugar de trabajo, en la cual se considera 7 o más una evaluación aceptable.

Los resultados fueron los siguientes:

				Medidas de Dispersión			
Nombre	Calificaciones			Promedio	Varianza	Desviación estándar	Coef. de Variación (%)
Práctico	8	8	8	8	0	0	0
Violinista	7	8	9	8	1	1	12.5
Flautista	6	8	10	8	4	2	25

Si observas, los tres presentan el mismo promedio en su evaluación. Esto pudiera hacernos pensar, equivocadamente, que los tres tienen el mismo desempeño. Sin embargo, observando los números nos damos cuenta de que Flautista fue evaluado con un 6 lo cual está por debajo del estándar deseado. Esto es un ejemplo claro de la importancia de **utilizar las medidas de tendencia central y siempre acompañarlas con las medidas de dispersión.**

Al analizar el resultado de la **varianza** de Práctico, nos encontramos con un **cero**. Esto **refleja** que las evaluaciones que recibió **siempre fueron las mismas, no cambiaron**.

Para realmente tener una idea de qué tan revelador es el resultado de la varianza es necesario compararlo con otros. Sin embargo, sí podemos llegar a la conclusión de que, **al aumentar el valor de la varianza, los datos están más alejados entre sí o más distantes unos de otros**.

Una desventaja de la varianza es que, dado que los resultados que muestra están al cuadrado, resulta una medida poco práctica, por lo que, en su lugar, debemos utilizar la desviación estándar.

En este ejemplo particular sí podemos utilizar la desviación estándar porque los promedios en los tres casos son iguales, lo cual no siempre sucede. **Cuando las medias sean diferentes, se aplica el coeficiente de variación**.

El coeficiente de variación se calcula dividiendo la desviación estándar entre la media y multiplicando por cien. Esto muestra que el coeficiente de variación es una medida relativa. Al aumentar el valor del coeficiente de variación, al igual que en las medidas de dispersión anteriores, los datos están más alejados entre sí o más distantes unos de otros.

$$CV = \frac{s}{\bar{x}} * 100$$

Coeficiente de Variación

$$\sigma^2 = \frac{\sum (x - \mu)^2}{N}$$

Varianza Poblacional

$$\sigma = \sqrt{\frac{\sum (x - \mu)^2}{N}}$$

Desviación Estándar Poblacional

$$R = \text{Máx} - \text{Min}$$

Rango

$$\text{RIQ} = Q_3 - Q_1$$

Rango Intercuartílico

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

Varianza Muestral

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

Desviación Estándar Muestral

Existen dos tipos de medidas de dispersión: **las absolutas** (que se manejan en unidades) y **las relativas** (que se manejan en porcentaje).

1. Absolutas

- 1.1. **Rango.** Es la más fácil de calcular y la menos utilizada, ya que sólo toma en cuenta los valores mayor y menor e ignora las variaciones de todas las demás observaciones, siendo afectada significativamente por los valores extremos. Esta medida se utiliza mucho en procesos automatizados con poca variabilidad, por ejemplo, en una empresa manufacturera.
- 1.2. El **rango intercuartil (IQR)** es una medida estadística de dispersión que representa la diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1) de un conjunto de datos:

$$\text{Rango intercuartil} = Q3 - Q1$$

Esto significa que el rango intercuartil abarca el 50 % central de los datos, lo que lo hace menos sensible a valores extremos o atípicos. Por ejemplo, si en una empresa se quiere analizar la distribución de salarios, sin verse afectada por sueldos extremadamente altos o bajos, el IQR ayudaría a medir la variabilidad del salario medio.

En resumen, el rango intercuartil es una herramienta útil para analizar la dispersión de los datos de manera robusta y para detectar posibles valores atípicos en un conjunto de datos.

- 1.3. **Varianza.** Medida del cuadrado de la distancia promedio entre la media y cada elemento del conjunto de datos. Tiene la desventaja de que sus unidades son al cuadrado, lo que hace que no tenga un sentido práctico o de realidad al querer utilizarla en la práctica.
- 1.4. **Desviación estándar.** Se obtiene sacando la raíz cuadrada de la varianza, esto hace que tanto la media como la desviación estándar tengan las mismas unidades, ya que las unidades en la varianza están elevadas al cuadrado.


2. Relativas

- 2.1. **Coeficiente de variación.** Se utiliza para determinar la dispersión de dos o más conjuntos de datos que poseen medias distintas. **Cuando las medias no son iguales** no podemos tomar una decisión respecto a las varianzas para decidir qué conjunto de datos tiene mayor o menor dispersión

Cabe resaltar, que **todas las medidas de dispersión ya sean absolutas o relativas necesitan para ser evaluadas un punto de comparación.** Es decir, el resultado en sí mismo no nos permite llegar a una conclusión. Sólo cuando se comparan dos o más situaciones es cuando se puede determinar en cuál hay menor dispersión.

Gran parte de los dueños de negocio están familiarizados con la **media o promedio** como indicador para evaluar resultados, y suelen basar muchas de sus decisiones en este dato. Pero, ¿qué tanto se reconoce la importancia de ir más allá y analizar también la **incertidumbre o riesgo** que revela la **dispersión de los datos**? La variabilidad no siempre recibe la misma atención que la media, quizá porque es menos intuitiva, aunque puede marcar la diferencia al entender qué tan estables, o impredecibles, son los procesos de tu negocio.

Ahora bien, una vez que comprendes no solo el “centro” de los datos, sino también qué tan dispersos están, surge una pregunta clave: **¿cómo es la forma de esa distribución?**, es decir, ¿los datos se concentran de manera simétrica, se inclinan hacia un lado o presentan picos y colas más extremas? Este siguiente paso nos lleva a las **medidas de forma**, que completan la visión del comportamiento de tus variables.



Medidas de forma

Imagina que quieres saber cómo se distribuye el ingreso de tus clientes alrededor del ingreso promedio. Pudiera ser que hay la misma cantidad de clientes con ingresos bajos que altos. O tal vez hay muchos clientes con ingresos altos y pocos con ingresos bajos, o viceversa, muchos clientes con ingresos bajos y pocos clientes con ingresos altos.

Para destacar la forma en que los datos se distribuyen alrededor de la media, puedes utilizar la medida del **sesgo**, también conocida como coeficiente de asimetría.


El **coeficiente de asimetría** indica si el número de elementos a la izquierda de la media aritmética es el mismo que la cantidad de observaciones del lado derecho. **Esta medida hace que no sea necesario hacer la gráfica para observar la distribución de los datos.**

Cuando **el sesgo es cero**, la distribución de los datos **está equilibrada** y se le denomina **simétrica**, es decir hay la misma cantidad de observaciones del lado izquierdo (valores menores) y del lado derecho (valores mayores) que la media. En el ejemplo que mencionamos al inicio, del ingreso de tus clientes, esto quiere decir que hay la misma cantidad de clientes con ingresos bajos que altos. Esta distribución **se caracteriza porque los valores de la media, la mediana y la moda coinciden**, si los datos presentan moda.

Cuando el **sesgo es positivo (o sesgo a la derecha)** la distribución de los datos se caracteriza porque la mayoría de los datos están concentrados en los valores más pequeños y son pocos datos los que se encuentran del lado derecho de la media. Otra forma de describirlo es: la cola a la derecha de la media es más larga que la de la izquierda. Además, **el valor de la media será mayor que el valor de la mediana**. En el caso del ingreso de tus clientes, esto quiere decir que tienes muchos clientes con ingresos bajos y pocos clientes con ingresos altos.

El caso contrario se observa cuando el **sesgo es negativo (o sesgo a la izquierda)** donde la distribución de los datos se caracteriza porque la mayoría de los datos están concentrados en los valores más grandes y son pocos datos los que se encuentran en los valores pequeños. Otra forma de describirlo es que la cola a la izquierda de la media es más larga que la de la derecha. Además, **el valor de la media será menor que el valor de la mediana**. En el caso del ingreso de tus clientes, esto quiere decir que tienes muchos clientes con ingresos altos y pocos clientes con ingresos bajos.

Determinar el sesgo podría serte de ayuda para tomar decisiones con respecto al precio de tus productos o servicios.



Sesgo:

Medida de la forma de una distribución de datos.

Si los datos tienen una **distribución simétrica**, entonces el **sesgo = 0**

$$\text{sesgo} = \frac{m_3}{(s^2)^{3/2}} \quad m_3 = \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{n}$$



En Excel, con la función **SKEW()** o **COEFICIENTE.ASIMETRIA()**, se puede obtener el sesgo de un grupo de datos.

| Curtosis

Mide la “cantidad de pico” que tiene una distribución, es decir **qué tan afilada o achatada es la distribución de los datos**.

Generalmente se toma como referencia la curtosis de la **distribución normal que es igual a 3, aunque en las aplicaciones estadísticas se reescalan y la referencia es 0**.

Dependiendo del grado de curtosis, tenemos tres tipos de distribuciones:

1 Leptocúrtica

Existe una gran concentración de los valores en torno a su media (curtosis >3). Esta curva tiene una forma muy afilada, lo que significa que hay poca variación entre los datos ya que se encuentran en un rango muy reducido alrededor de la media aritmética. En el caso del ingreso de tus clientes, esto quiere decir que la mayoría de tus clientes tienen ingresos muy cercanos a la media.

2 Mesocúrtica

Existe una concentración normal de los valores en torno a su media (curtosis $=3$). Lo que implica que a una desviación estándar con respecto a la media se encuentra el 68 % de los datos, a dos desviaciones estándar el 95 % y a tres desviaciones estándar se encuentran aproximadamente el 100 % de los datos. En el caso del ingreso de tus clientes, esto quiere decir que el 68 % de tus clientes tienen ingresos en un rango que está a una desviación estándar de distancia por arriba y por debajo de la media.


3 Platicúrtica

Existe una baja concentración de los valores en torno a su media (curtosis <3). Esta distribución de los datos tiene forma muy achatada o muy extendida, lo que significa que el rango de datos es muy amplio. En el caso del ingreso de tus clientes, esto quiere decir que la mayoría de tus clientes tienen ingresos en un rango muy amplio, alejándose de la media.

Veámoslo resumido en una imagen:

Leptocúrtica

$$K > 3$$



Valores mayores de 3 tienden a curvas leptocúrticas.

Mesocúrtica


$$K = 3$$



La referencia es la distribución normal que tiene una curtosis de 3.

Platicúrtica

$$K < 3$$



Valores menores de 3 tienden a curvas platicúrticas.

En Excel y en algunos paquetes estadísticos la referencia de K es 0 (CERO)

Curtosis:

Mide la “cantidad de pico” que tiene una distribución.

Generalmente se toma como referencia la curtosis de la **distribución normal que es igual a 3**.

$$\text{Curtosis} = \frac{m_4}{(s^2)^2}, \text{ donde } m_4 = \frac{\sum_{i=1}^n (x_i - x)^4}{n}$$



En Excel, con la función **KURT ()** o **CURTOSIS()**, se puede obtener la curtosis de un grupo de datos.


Para terminar...

Las medidas de forma son imprescindibles para tomar decisiones en tu día a día. Considera que en tu negocio estás contemplando añadir dos nuevos productos para ofrecerlos a tus clientes frecuentes, uno de ellos es para un sector de la población con un poder adquisitivo mayor, y el otro es mucho más asequible. Tú tienes una base de datos de tus clientes actuales, incluyendo el dato de su ingreso mensual promedio. Responde:

- ¿Cómo podría ayudarte a analizar el sesgo de esta información?
- ¿Cómo debería ser el coeficiente de simetría para tomar la decisión de ofrecer el producto más costoso?
- ¿De qué otra forma las medidas de dispersión te pueden ayudar a tomar decisiones en tu día a día?

Reto final: ¿Te sientes capaz de elaborar y analizar un reporte ejecutivo que proponga mejoras en tu organización a partir del comportamiento de las variables críticas del negocio?

Por último, si quieres saber más de los temas revisados en esta lección, te invitamos a descargar desde Archivos adjuntos, el PDF: **Conoce las medidas resumen.**



Descarga este documento en la sección “**Archivos adjuntos**” de la plataforma.