



Conoce las medidas resumen

| Medidas de Tendencia central

¿Para qué sirven las medidas resumen?

Ayudan a **sintetizar las características dominantes de un conjunto de datos** a través del cálculo de unas cifras que sean representativas de la muestra o de la población.

Ya que no siempre es posible analizar por completo la población, podemos seleccionar un subconjunto (muestra), y a partir de ella se estiman los valores poblacionales.

Es necesario mencionar que estas medidas resumen se clasifican en tres tipos: las de **tendencia central**, las de **dispersión** y las de **forma**. En este recurso nos centraremos en las medidas de **Tendencia central**.

Pero, espera...

Antes de revisar dicha clasificación, es necesario aclarar dos términos con los que te encontrarás al realizar este tipo de análisis, estos son:

■ **Parámetro**

Representa una medida que describe el comportamiento de los datos poblacionales; se representan con letras griegas tales como μ llamada miu y σ conocida como sigma.

■ **Estadístico**

Nos representa una medida que describe el comportamiento de los datos muestrales, para los cuales se utilizan letras latinas como $\bar{x}$ (denominada equis testada), s (ese que describe la desviación estándar en la muestra), entre otras.

Con esto claro, pasemos con las primeras medidas, las de tendencia central.

Medidas de tendencia central

Son medidas que suelen ubicarse en el centro de los datos y nos indican el punto medio o **valor típico** de los datos. Se les llama así porque generalmente la acumulación más alta de datos se encuentra en los valores intermedios y son aquellas medidas que nos ayudan a saber dónde están los datos, pero sin indicar cómo se distribuyen. Si bien la media aritmética es la más conocida, existen otras como la media ponderada, la media geométrica, la mediana o segundo cuartil y, la moda. **Las medidas de tendencia central más utilizadas y en las que nos enfocaremos son: media, mediana y moda.** ¿Las revisamos a detalle?, pero antes, veamos un ejemplo.

Ejemplo

Conocer el tiempo que te toma alistarte en la mañana te puede ayudar a llegar a tiempo todos los días. Para lograrlo, primero debes definir claramente qué vas a medir. En este caso es el tiempo que te toma alistarte, que abarca desde que te levantas de la cama, hasta el momento en el que sales de casa, redondeado al minuto más cercano. Entonces podrás recolectar los tiempos de 10 días laborales consecutivos y organizarlos de la siguiente manera:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	43	52	39	44	40	31	44	35

Fuente: Berenson, M., Levine, D., Szabat, K., y Stephen, D. (2017).

Utilicemos este ejemplo para estudiar las tres principales medidas de tendencia central, comencemos por la **media**.

Media Aritmética

¿Qué es el promedio?

Se trata de la medida de tendencia central más importante para una variable, pues proporciona una medida de la ubicación central de los datos. Suele sugerir punto de equilibrio en el conjunto de datos, similar al punto de apoyo de una balanza. La media es la medida en la cual todos los valores tienen el mismo peso o importancia. Se representa como μ (miu) cuando es la media de la población y como $\bar{x}$, (equis testada) cuando es la media de la muestra.

Para su cálculo, se utiliza siguiente fórmula:

$$\bar{x} = \frac{\text{suma de todos los valores}}{\text{cantidad de observaciones}} = \frac{\sum_{i=1}^n x_i}{n}$$

La letra griega Σ es el signo de sumatoria.

x_i representa cada observación.

n el total de observaciones en la muestra.

¿Cómo se aplica a nuestro ejemplo?

$$\bar{x} = \frac{39+29+29+43+52+39+44+40+31+44+35}{10} = \frac{396}{10} = 39.6$$

A pesar de que ninguno de los días en los que recolectaste información tiene el valor de 39.6 minutos, el tomar esta cantidad de tiempo para alistarte en las mañanas es una decisión razonable que puedes hacer.

La media es una buena medida de tendencia central en este caso debido a que la información no tiene algún valor excepcional (atípico) en los valores menores o en los valores mayores.

■ Pero, ¿qué pasa cuando existe un valor tan diferente a los demás?

En un caso así, la media puede ser afectada, imagina que en el día 3 un conjunto de circunstancias inusuales te retrasaron para estar listo, por lo que el tiempo de ese día fue de 103 minutos. Este valor extremo causa que la media suba a 45.6 minutos de la siguiente manera:

$$\underline{x} = \frac{\text{suma de todos los valores}}{\text{cantidad de observaciones}} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\underline{x} = \frac{39+29+103+43+52+39+44+40+31+44+35}{10} = \frac{456}{10} = 45.6$$


El valor extremo ha incrementado la media en 6 minutos. Dicho valor también movió el valor de la media con respecto a todos los valores. La media original, 39.6 minutos, se encontraba en el medio o tenía una posición central con respecto a todos los valores: 5 de los tiempos eran menores que la media y 5 de los tiempos eran mayores que la media. En contraste, usando el valor extremo, la media es mayor que 9 de los 10 valores, haciendo que la nueva media sea una medida pobre de tendencia central.

¿Y cuáles son las propiedades de la media aritmética?

Podemos destacar dos propiedades principales:

1. La suma de las distancias (desviaciones) entre los valores o datos, respecto a su media aritmética, es cero.

$$\sum_{i=1}^n (x - \bar{x}) = 0$$




Fuente: adaptado de USAP, 2014-1

Esto significa que **es el centro de gravedad (equilibrio)** de toda distribución, y representa a todos los valores observados. Como se aprecia en la imagen, las distancias negativas con respecto a la media siempre serán iguales a las distancias positivas, por lo que la sumatoria siempre será 0.

2. La suma de los cuadrados de las distancias (desviaciones) entre los valores o datos, respecto a su media aritmética, es un valor mínimo.

$$\sum_{i=1}^n (x - \bar{x})^2 = \text{Valor mínimo}$$

	Tiempo (x)	Suma de cuadrados
	29	1536
	31	1152
	35	624
	39	416
	39	416
Media	39.6	412.4
	40	414
	43	528
	44	606
	44	605
	52	1950



Esto significa que ninguna otra cantidad (o dato) del conjunto de datos dará una cantidad menor a la que proporciona la media. **De esta propiedad surge el concepto de la varianza, y de la desviación estándar.**

Mediana

También es conocida como percentil 50 o segundo cuartil. Es una medida de orden, por lo que será necesario organizar los datos de menor a mayor para calcularla. Es el punto central de la distribución. En otras palabras, es el valor tal que, la mitad de los datos de la distribución son menores a la mediana y la otra mitad son mayores a la mediana.

$$\text{Lugar que ocupa la mediana} = \frac{n + 1}{2}$$

Esto nos indica que la mediana depende de la cantidad de datos que se estén analizando, más que del valor de los propios datos. Para calcularla deberás seguir una de las dos reglas:

Regla 1: si el conjunto de datos contiene una cantidad de valores **impar**, la mediana es el dato o valor que se ubica en el centro de los datos ordenados de menor a mayor.

Regla 2: si el conjunto de datos contiene una cantidad de valores **par**, la mediana es el promedio de los dos datos o valores centrales del conjunto de datos ordenados de menor a mayor.

■ Ejemplo con cantidad de datos pares

Retomando nuestro ejemplo del tiempo que te toma alistarte por las mañanas, los datos originales son:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	43	52	39	44	40	31	44	35

Ahora, al ordenarlos de menor a mayor resulta lo siguiente:

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	43	44	44	52

En nuestro ejemplo tenemos 10 datos, por lo que el lugar que ocupa la mediana sería:

$$\text{Lugar que ocupa la mediana} = \frac{n + 1}{2} = \frac{10 + 1}{2} = 5.5$$

Al tratarse de una cantidad de datos par, aplicarás la regla 2, por lo que calcularás el promedio de los valores en la 5ta. y 6ta. posición correspondientes en nuestro ejemplo a 39 y 40. Por lo tanto, la mediana es:

$$\textit{Mediana} = \frac{39 + 40}{2} = 39.5$$

La mediana de 39.5 minutos significa que la mitad de los días el tiempo para alistarte es menor o igual que 39.5 minutos, mientras que en la otra mitad de los días el tiempo para alistarte es mayor o igual que 39.5. En este caso, la mediana de 39.5 se encuentra muy cercana a la media de 39.6 minutos.

Retomando el ejercicio de sustituir el valor del día 3, de 43 minutos, por un valor extremo de 103 minutos, los valores originales eran:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	103	52	39	44	40	31	44	35

Posteriormente, al ordenarlos de menor a mayor, quedan de la siguiente manera:

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	44	44	52	103

El lugar que ocupa la mediana sería:

$$\text{Lugar que ocupa la mediana} = \frac{n + 1}{2} = \frac{10 + 1}{2} = 5.5$$

$$\text{Mediana} = \frac{39 + 40}{2} = 39.5$$

La media cambió de 39.6 a 45, es decir, aumentó en 6 minutos. Se observa que la mediana no se ve afectada, pues permanece en 39.5 minutos. Este ejemplo muestra que **la mediana no se altera por la presencia de valores extremos**.

■ Ejemplo con cantidad de datos pares

Los datos nutricionales de una muestra de siete cereales incluyen el número de calorías por porción:

Cereal	Calorías
Kellogg's All Bran	80
Kellogg's Corn Flakes	100
Wheaties	100
Nature's Path Organic Multigrain Flakes	110
Kellogg's Rice Krispies	130
Post Shredded Wheat Vanilla Almond	190
Kellogg's Mini Wheats	200

Al ordenarlos de menor a mayor, quedan de la siguiente manera:

Orden	1	2	3	4	5	6	7
Tiempo (min)	80	100	100	110	130	190	200

El lugar que ocupa la mediana sería:

$$\text{Lugar que ocupa la mediana} = \frac{n + 1}{2} = \frac{7 + 1}{2} = 4$$

Dado que la cantidad de datos es impar, aplicas la regla 1, quedando entonces:

$$\text{Mediana} = 110$$

La mediana en el número de calorías es de 110. Esto significa que la mitad de los cereales tiene 110 o menos calorías por porción, y la otra mitad de los cereales tiene 110 o más calorías por porción.

Moda

Se trata del valor con mayor frecuencia, o el que más se repite, en el conjunto de datos. Al igual que en el caso de la mediana, y a diferencia de en la media, los valores extremos o atípicos no afectan a la moda.

Cuando existen dos valores que tienen más frecuencia que el resto de los datos, se dice que la distribución de datos es **bimodal**. Si se tienen más de dos valores modales, la distribución es **multimodal** y la **moda pierde representatividad**. Si todos los valores ocurren con la misma frecuencia se dice que **no existe moda**.

Veamos algunos ejemplos.

Datos bimodales

Retomando nuestro ejemplo del tiempo que te toma alistarte por las mañanas, los datos originales son:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	43	52	39	44	40	31	44	35

Existen dos modas: 39 minutos y 44 minutos. Esto es porque ambos valores ocurren dos veces.

Datos sin moda

Se ha tomado una muestra de los precios (en dólares) de 14 teléfonos inteligentes ofrecidos por un proveedor:

Teléfono	1	2	3	4	5	6	7	8	9	10	11	12	13	14
Precio	56	71	73	74	90	179	213	217	219	225	240	250	500	513

No existe moda, ya que ninguno de los valores es más típico, es decir, cada valor aparece el mismo número de veces (una vez) en el conjunto de datos.

Ventajas e inconvenientes de las medidas de tendencia central

Ventajas

Inconvenientes

Media Aritmética

- La media aritmética viene expresada en las mismas unidades que la variable.
- Todos los valores de la distribución tienen la misma importancia.
- Es única.
- En su cálculo intervienen todos los valores de la distribución.
- Es el centro de gravedad de toda distribución, representando a todos los valores observados.

- No puede ser utilizada en datos cualitativos
- Su principal inconveniente es que se ve afectada por los valores extremadamente grandes o pequeños de la distribución.

Mediana	● Es fácil de calcular. ● Es la medida más representativa en el caso de variables que sólo admiten la escala ordinal. ● En la mediana sólo influyen los valores centrales y es insensible a los valores atípicos (extremos) u "outliers".	● En su determinación no intervienen todos los valores de la variable.
Moda	● Es fácil de calcular. ● Es la medida más representativa en el caso de variables que sólo admiten la escala nominal. ● Al igual que la mediana, no se ve afectada por valores extremos o atípicos.	● Es muy frecuente que todos los datos sean valores diferentes y ahí no hay moda. ● Se enfoca en el valor de mayor frecuencia e ignora al resto de los datos. ● Puede haber más de una moda (sugiere la existencia de varias poblaciones).

Para terminar, vale la pena mencionar un error que sucede cuando existen valores atípicos y, aún así, la media y la mediana son similares es que se decide utilizar la mediana al momento de resumir un conjunto de datos. Sin embargo, la forma para calcularlas es muy distinta, ya que mientras la media toma en cuenta todos los valores, la mediana se enfoca en el valor central. Por lo tanto, **la media es mucho más representativa que la mediana** en un conjunto de datos.

Medidas de Dispersión

¿Qué es la dispersión?

También llamada **variación**, es el grado en que los datos numéricos tienden a extenderse alrededor de un valor medio, mostrando qué tan parecidos, o no, son los datos entre sí. Según sea el entorno o la situación en la que se está utilizando la dispersión, mostrará una cualidad adicional, ya sea **calidad, riesgo, consistencia, eficiencia**, etc. Esto nos lleva a la necesidad de plantearnos siempre la pregunta: ¿En este caso qué refleja la variabilidad?

Las medidas de variación

Una medida de variación es el **rango**, que se calcula obteniendo la **diferencia entre el dato mayor y el dato menor** del conjunto de datos. Sin embargo, se trata de una medida frágil debido a que no toma en cuenta todos los datos, sino solo los extremos, además de que es afectada significativamente por los valores extremos. **Es útil en casos donde la variación es muy pequeña.**

$$\text{Rango} = \text{Valor máximo} - \text{Valor mínimo}$$

$$R = \text{Máx} - \text{Mín}$$

Sin embargo, las medidas de variabilidad más utilizadas son **la desviación estándar y la varianza**. Para comprender mejor estos conceptos, veamos un ejemplo.

■ Por ejemplo

¿Recuerdas la historia de los tres cochinitos? Ellos son Práctico, Violinista y Flautista. Un día traen sus calificaciones a casa, y son las siguientes. Considera que para aprobar una materia requiere de una calificación mínima de 7.

Nombre	Calificaciones			Promedio
Práctico	8	8	8	8
Violinista	7	8	9	8
Flautista	6	8	10	8

Puedes ver que los tres tienen el mismo promedio en sus calificaciones, pero no tienen el mismo desempeño escolar. Al observar los números queda claro que Flautista obtuvo una calificación de 6, que no es suficiente para aprobar. Este es un ejemplo claro de la importancia de **utilizar las medidas de tendencia central y siempre acompañarlas con las medidas de dispersión**.

Ahora, veamos las medidas de dispersión más utilizadas y sus correspondientes fórmulas.

$$CV = \frac{s}{\bar{x}} * 100$$

Coeficiente de Variación

$$\sigma^2 = \frac{\sum (x - \mu)^2}{N}$$

Varianza Poblacional

$$\sigma = \sqrt{\frac{\sum (x - \mu)^2}{N}}$$

Desviación Estándar Poblacional

$$R = \text{Máx} - \text{Min}$$

Rango

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1}$$

Varianza Muestral

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

Desviación Estándar Muestral

$$RIQ = Q_3 - Q_1$$

Rango Intercuartílico



Medida relativa expresada en porcentaje



Medida absoluta expresada en las unidades de la variable

- Son medidas que tratan de medir el **grado de dispersión** que tiene una variable estadística en torno a una medida de posición o tendencia central, **indicándonos lo representativa que es la medida de posición**.

La varianza

Es una medida de la variabilidad que utiliza todos los datos. Su cálculo se basa en medir la distancia de cada observación con respecto a la media, por lo que nos indica qué tan cercanos o distantes se encuentran los datos en relación al valor central.

■ ¿Cómo se calcula?

La varianza se calcula con las diferencias entre el valor de cada observación, x_i , y la media. La diferencia entre cada observación x_i y la media se llama **desviación respecto de la media**. Para una muestra, una desviación respecto de la media se escribe $(x_i - \bar{x})$. Para una población se escribe $(x_i - \mu)$. Si se desea calcular la varianza, las desviaciones respecto de la media se elevan al cuadrado. Esto hará que cuando la distancia sea grande, y se eleve al cuadrado, el valor de la varianza se incrementará de forma significativa.

Veamos un ejemplo.

■ Pero, ¿qué pasa cuando existe un valor tan diferente a los demás?

Como ejemplo de cómo se obtiene la varianza, harás el cálculo para las calificaciones de Flautista, para lo cual asumirás que se trata de una muestra. Por lo tanto, la fórmula a utilizar será:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

$$s^2 = \frac{(6 - 8)^2 + (8 - 8)^2 + (10 - 8)^2}{3 - 1} = \frac{8}{2} = 4$$

La varianza de 4 por sí misma no puede ser interpretada. Es necesario compararla con otras varianzas para que tenga un significado.

Aplicando la misma fórmula, el resultado de la **varianza** de Práctico es **cero** (lo cual refleja que las evaluaciones que recibió **siempre fueron las mismas, no cambiaron**, en todos los casos las calificaciones fueron 8). Mientras que la varianza de las calificaciones de Violinista es de 1.

Nombre	Calificaciones			Promedio	Varianza
Práctico	8	8	8	8	0
Violinista	7	8	9	8	1
Flautista	6	8	10	8	4

Al observar las varianzas Práctico = 0, Violinista = 1 y Flautista = 4; puedes concluir que **al aumentar el valor de la varianza, los datos están más alejados entre sí**.

■ ¿La varianza presenta desventajas?

Una desventaja es que, dado que los resultados están al cuadrado, sus unidades también lo están. Por lo que resulta una medida de la que cuesta obtener una interpretación intuitiva de su valor numérico. Además, sus unidades son distintas a las de la media y a las de los datos originales, por lo que no se pueden comparar entre sí. Ésta es la razón por la que la varianza no es muy comúnmente usada, y en su lugar debemos de utilizar la **desviación estándar (s)** (es la raíz cuadrada positiva de la varianza y su interpretación es la misma que la varianza, corrigiendo así el problema de las unidades cuadradas).

$$\text{Desviación estándar} = \sqrt{\text{Varianza}}$$

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Retomando el ejemplo de los 3 cerditos, las desviaciones estándar son:

Práctico = 0, Violinista = 1 y Flautista = 2

					Medidas de Dispersión	
Nombre	Calificaciones			Promedio	Varianza	
Práctico	8	8	8	8	0	0
Violinista	7	8	9	8	1	1
Flautista	6	8	10	8	4	2

Estos resultados ya están medidos en puntos de calificación, por lo que son las mismas unidades que los datos originales; por esta razón la desviación estándar se compara más fácilmente con la media y con otros datos estadísticos que se miden en las mismas unidades que los datos originales.

En este ejemplo, sí podemos comparar las desviaciones estándar de los cerditos y observar que al incrementarse el valor de la desviación estándar, nos indica que las calificaciones son más distintas entre sí. Estas comparaciones entre las desviaciones estándar se pueden realizar porque las medias aritméticas en los tres casos son iguales, lo que no siempre sucede. **Cuando las medias sean diferentes, se aplica el coeficiente de variación.**

■ Pero, ¿qué es el coeficiente de variación?

Es una medida relativa de la variabilidad; mide la desviación estándar respecto de la media. Se utiliza cuando las variables tienen tanto desviaciones estándar como medias distintas. **Se calcula dividiendo la desviación estándar entre la media y multiplicando por cien.** Esto muestra que el coeficiente de variación es una medida relativa. Al aumentar el valor del coeficiente de variación, al igual que en las medidas de dispersión anteriores, los datos están más alejados entre sí o más distantes unos de otros.

$$\text{Coeficiente de Variación} = \frac{\text{Desviación estándar}}{\text{Media}} * 100$$

$$CV = \frac{s}{\bar{x}} * 100$$

Para el caso de nuestro ejemplo de las calificaciones, los resultados son:

Práctico = 0%, Violinista = 12.5% y Flautista = 25%

Esto confirma una vez más que al aumentar el valor del coeficiente de variación, las calificaciones se encuentran más alejadas entre sí o más distantes unas de otras.

				Medidas de Dispersión			
Nombre	Calificaciones			Promedio	Varianza	Desviación estándar	Coef. de Variación (%)
Práctico	8	8	8	8	0	0	0
Violinista	7	8	9	8	1	1	12.5
Flautista	6	8	10	8	4	2	25

¡Ojo!

Cabe resaltar, que **todas las medidas de dispersión ya sean absolutas o relativas necesitan para ser evaluadas un punto de comparación.** Es decir, el resultado en sí mismo no nos permite llegar a una conclusión. Sólo cuando se comparan dos o más situaciones es cuando se puede determinar en cuál hay menor dispersión.

Medidas de forma

El sesgo es una medida de forma que indica qué tan simétrica es la distribución de los datos alrededor de la media. Recordarás del tema de gráficos que un histograma simétrico es aquel que tiene forma de campana y cuyos datos antes de la media están distribuidos exactamente igual que los valores después de la media.


Para destacar la forma en que los datos se distribuyen alrededor de la media, puedes utilizar la medida del **sesgo**, a dicha medida también se le conoce como **coeficiente de asimetría**. Existen tres posibilidades con las que te puedes enfrentar:

Media menor que ($<$) mediana: El sesgo es negativo o distribución sesgada hacia la izquierda.

Media igual ($=$) a mediana: Es una distribución simétrica o con sesgo cero.

Media mayor que ($>$) mediana: El sesgo es positivo o distribución sesgada hacia la derecha.

Tipos de sesgo




El **coeficiente de asimetría** indica si el número de elementos a la izquierda de la media aritmética es el mismo que la cantidad de observaciones del lado derecho. **Esta medida hace que no sea necesario hacer la gráfica para observar la distribución de los datos.**

$$\text{Coeficiente de asimetría} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

Cuando **el sesgo es cero**, la distribución de los datos **está equilibrada** y se le denomina **simétrica**, es decir hay la misma cantidad de observaciones del lado izquierdo (valores menores) y del lado derecho (valores mayores) que la media. En el ejemplo que mencionamos al inicio, del ingreso de tus clientes, esto quiere decir que hay la misma cantidad de clientes con ingresos bajos que altos. Esta distribución **se caracteriza porque los valores de la media y la mediana y la moda coinciden**, siempre y cuando los datos presenten una sola moda.

En el tema de gráficos, la siguiente figura fue tu referente en cuanto a los tipos de formas de los datos:



Fuente: adaptado de Teachoo, 2023


Podrás ver que a los gráficos a) y f) se les denomina simétricos. Esto quiere decir que su coeficiente de asimetría es cero.

Cuando el **sesgo es positivo (sesgo a la derecha)** la distribución de los datos se caracteriza porque la mayoría de ellos están concentrados en los valores más pequeños y son pocos los que se encuentran del lado derecho de la media. Además, **el valor de la media será mayor que el valor de la mediana**. En el caso del ingreso de tus clientes, esto quiere decir que tienes muchos clientes con ingresos bajos y pocos clientes con ingresos altos.

El caso contrario se observa cuando el **sesgo es negativo (sesgo a la izquierda)** donde la distribución de los datos se caracteriza porque la mayoría están concentrados en los valores más grandes y son pocos datos los que se encuentran en los valores pequeños. Además, **el valor de la media será menor que el valor de la mediana**. En el caso del ingreso de tus clientes, esto quiere decir que tienes muchos clientes con ingresos altos y pocos clientes con ingresos bajos.

¿Por qué es importante determinar el sesgo? Esto podría ayudarte a tomar decisiones con respecto al precio de tus productos o servicios, ya que tendrás una idea de cómo está distribuido el ingreso de tus clientes.

En general, podemos decir que el sesgo es:



Sesgo:

- Medida de la forma de una distribución de datos.
- Si los datos tienen una **distribución simétrica**, entonces el **sesgo = 0**

$$\text{Coeficiente de asimetría} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$



En Excel, con la función **SKEW()** o **COEFICIENTE.ASIMETRIA()**, se puede obtener el sesgo de un grupo de datos.

Curtosis

Esta es una característica de forma en una distribución. **Mide la “cantidad de pico” que tiene una curva de distribución**, es decir, qué tan afilada o achatada es la distribución de los datos alrededor de la media.

Generalmente se toma como referencia la curtosis de la **distribución normal que es igual a 3**, aunque en las aplicaciones estadísticas se reescalan y la referencia es 0.


El cálculo de la curtosis se realiza utilizando la siguiente fórmula:

$$\text{Curtosis} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4}$$

Dependiendo del grado de curtosis, tenemos tres tipos de distribuciones:

1. **Leptocúrtica (curtosis > 3):** Existe una gran concentración de los valores en torno a su media (curtosis > 3). Esta curva tiene una forma muy afilada, lo que significa que hay poca variación entre los datos ya que se encuentran en un rango muy reducido alrededor de la media aritmética. En el caso del ingreso de tus clientes, esto quiere decir que la mayoría de tus clientes tienen ingresos muy cercanos a la media.
2. **Mesocúrtica (curtosis $= 3$):** Existe una concentración normal de los valores en torno a su media (curtosis $= 3$). Lo que implica que los valores están distribuidos de la misma manera antes de la media que después de la media en forma espejo. En el caso del ingreso de tus clientes, esto quiere decir que el 50 % de tus clientes tienen ingresos menores a la media, mientras que el otro 50 % tiene ingresos por encima de la media.
3. **Platicúrtica (curtosis < 3):** Existe una baja concentración de los valores en torno a su media (curtosis < 3). Esta distribución de los datos tiene forma muy achatada o muy extendida, lo que significa que el rango de datos es muy amplio. En el caso del ingreso de tus clientes, esto quiere decir que la distribución de los ingresos tiene una variabilidad muy grande, alejándose de la media.

Medidas de forma: curtosis



En Excel y en algunos paquetes estadísticos la referencia de K es 0 (CERO)

Curtosis:

Mide la “cantidad de pico” que tiene una distribución.

Generalmente se toma como referencia la **curtosis** de la **distribución normal** que es igual a 3.

$$curtosis = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4}$$



En Excel, con la función **KURT ()** o **CURTOSIS()**, se puede obtener la curtosis de un grupo de datos.

Ejemplo integrador

Se llevó a cabo en el año 2016 un estudio analizando las velocidades de descarga y carga en mbps para los nueve principales proveedores de internet en Estados Unidos. La información obtenida es la siguiente:

c	Velocidad de descarga	Velocidad de carga
Verizon	24.0	14.3
T-Mobile	22.7	13.2
AT&T	20.8	9.1
Metro PCS	16.7	11.1
Sprint	11.2	6.4
Virgin Mobile	10.8	6.2
Boost	10.3	6.0
Straight Talk	7.1	3.0
Cricket	4.5	3.8

Fuente: Berenson, M., Levine, D., Szabat, K., & Stephen, D. (2017)

A continuación, podrás ver el resumen de las medidas numéricas de tendencia central, dispersión y forma correspondiente a los proveedores de internet:

	Velocidad de descarga (Mbps)	Velocidad de carga (Mbps)
Media	14.2333	8.1222
Mediana	11.2	6.4
Valor mínimo	4.5	3
Valor máximo	24	14.3
Rango	19.5	11.3
Varianza	49.795	16.2319
Desviación estándar	7.0566	4.0289
Coefficiente de variación	49.58%	49.60%
Sesgo (coeficiente de asimetría)	0.1932	0.3862
Curtosis	-1.5292	-1.2358
Tamaño de la muestra	9	9

■ ¿Qué conclusiones podemos obtener con base en esta información?

- La media es mayor que la mediana, tanto para la velocidad de descarga como para la de carga. Esto indica una distribución sesgada positiva o a la derecha.
- La curtosis es negativa tanto para la velocidad de descarga como para la de carga. Esto te dice que la distribución está menos afilada que la distribución normal. Es decir, su forma es platicúrtica o aplanada. Esto se puede observar además debido a que los rangos tienen valores de 19.5 para descarga y 11.3 para carga.
- La media de descarga es mucho más grande que la media de carga: 14.23 vs. 8.12 mbps.
- La mediana de descarga indica que la mitad de los proveedores tienen una velocidad de descarga de al menos 11.2 mbps, comparado con la mediana de la velocidad de carga de 6.4, la cual indica que la mitad de los proveedores tiene una velocidad de carga de al menos 6.4 mbps.
- Si bien, las desviaciones estándar son distintas (7.0566mbps vs. 4.0289mbps), los coeficientes de variación son muy similares (49.58 % vs. 49.60 %). ¿Consideras que estas diferencias son típicas entre los proveedores de internet?

📊 Detección de observaciones atípicas

Las observaciones atípicas son datos inusualmente grandes o sumamente pequeños dentro de un banco de datos. Dado que dichos valores atípicos impactan a los indicadores estadísticos, como la media y la desviación estándar, es necesario que sean detectados y analizados para tomar la decisión de incluirlos o excluirlos del análisis.

Los métodos utilizados para detectar las observaciones atípicas son el Valor z y el *box plot*. El primero utiliza como referencias la media y la desviación estándar, mientras que el segundo utiliza como referencia la mediana y el rango intercuartílico. A continuación ahondaremos en cada una de ellas:


■ Valor Z o puntuación Z

Una manera de detectar observaciones atípicas es mediante el valor z , el cual es una medida de posición relativa que ayuda a determinar a qué distancia de la media se encuentra un valor determinado. Esta distancia se mide con base en la cantidad de desviaciones estándar que la observación x_i tiene con respecto a la media. El valor z se llama valor estandarizado. Para su cálculo, se utiliza la siguiente ecuación:

$$\text{Valor } z = z_i = \frac{(x_i - \bar{x})}{s}$$

- z_i cantidad de desviaciones estándar que la observación x_i tiene con respecto a la media.
- x_i representa cada observación.
- $\bar{x}$ representa la media de los datos.
- s es la desviación estándar de la muestra.



Por ejemplo, $z_1=1.2$ indicaría que x_1 es 1.2 desviaciones estándar mayor que la media muestral. De modo similar, $z_2=-0.5$ indicaría que x_2 es 0.5 desviaciones estándar menor que la media muestral. A continuación, a manera de ejemplo, te mostramos las calificaciones de un grupo con media de 7 y desviación estándar de 1, donde se muestran los valores de z correspondientes:



Notarás que, para una calificación de 9, su puntaje sería +2. Es decir, el signo de + implica que el valor es mayor a la media, y el 2 significa que la calificación de 9 está a 2 desviaciones estándar de la media. Por el contrario, una calificación de 4 tiene un valor de z de -3. El signo negativo indica que es un valor menor a la media, y el valor de 3 nos dice que está a tres desviaciones estándar de la media. La diferencia entre los números 2 y 3 muestra que el 9 está más cerca de 7 que lo que está la calificación de 4.

El valor de z para cualquier observación o dato puede interpretarse como una medida de la posición relativa de la observación en un conjunto de datos. Por lo tanto, se dice que las observaciones de dos conjuntos de datos diferentes, con el mismo valor z , tienen la misma posición relativa en términos de que representan igual número de desviaciones estándar con respecto a la media.

Cuando los datos tienen una **distribución normal o de campana**, casi todos los valores (99.73 % de ellos) se encuentran dentro de tres desviaciones estándar con respecto a la media. Así, al usar puntuaciones z para identificar observaciones atípicas se recomienda tomar en cuenta como **una observación atípica cualquier valor con una puntuación z menor que -3 o mayor que +3**.



Fuente figura izquierda: adaptado de Matemáticas10, 2017.
Fuente figura derecha: adaptada de Datafluency.Academic, 2021.

Puedes observar en estos gráficos los porcentajes de datos que teóricamente se esperan según su posición relativa con respecto a la media cuando los datos están distribuidos de forma normal o de campana.

Retomando el ejercicio del tiempo que te toma alistarte por las mañanas, donde se observó un valor extremo de 103 minutos, los datos eran:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	103	52	39	44	40	31	44	35

Posteriormente, al ordenarlos de menor a mayor, quedan de la siguiente manera:

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	44	44	52	103

Puedes observar que el dato más grande (en la posición 10) es considerablemente mayor que su anterior inmediato (posición 9). Es natural que te surja la pregunta de si dicho dato más grande es realmente un valor atípico, por lo que decides usar la puntuación z para averiguarlo.

Notarás que, para poder obtener la puntuación z , es necesario primeramente calcular la media y la desviación estándar de los datos. Posteriormente calculas el valor z para cada observación. La tabla correspondiente es la siguiente:

Orden	Tiempo (min)	z_i
1	29	-0.78
2	31	-0.69
3	35	-0.50
4	39	-0.31
5	39	-0.31
6	40	-0.26
7	44	-0.08
8	44	-0.08
9	52	0.30
10	103	2.70
Media	45.6	
Desviación estándar	21.24	

Al observar el valor z del dato en la posición 10 (el cual es 103), te das cuenta que su valor no es mayor a 3, por lo que en teoría no se consideraría como valor atípico. Sin embargo, intuitivamente dudas del resultado ya que sabes que los valores atípicos por sí mismos alteran el valor de la media y de la desviación estándar. Debido a esto, procedes a recalcular la media y la desviación estándar, ahora sin tomar en cuenta el valor de 103, el cual sospechas que está inflando los valores de la media y la desviación estándar.

Una vez teniendo los nuevos valores de la media y la desviación estándar (ya sin incluir el 103), procedes a recalcular los valores de z . El resultado es el siguiente:



Orden	Tiempo (min)	z_i
1	29	-1.45
2	31	-1.16
3	35	-0.60
4	39	-0.03
5	39	-0.03
6	40	0.11
7	44	0.68
8	44	0.68
9	52	1.81
10	103	9.02
Media	39.22	
Desviación estándar	7.07	

El valor de la media pasó de 45.6 a 39.22. Por otro lado, el valor de la desviación estándar pasó de 21.24 a 7.07. Tu intuición estaba en lo cierto. El quitar el valor de 103, aunado con el hecho de que la cantidad de datos que tienes es pequeña, ha hecho que el valor de la media y el de la desviación estándar cambien considerablemente. Debido a esto, ahora el valor z del dato en la posición 10 (103) es de 9.02, el cual es mayor a 3, por lo que ahora sí queda demostrado que lo debes considerar un valor atípico.

Box Plot

Otra representación gráfica de mucha utilidad para identificar datos atípicos y para resaltar características importantes en un grupo de datos cuantitativos **es el box plot o Diagrama de Caja**. Esto será particularmente útil en los casos en que las distribuciones de datos sean muy sesgadas o incluso bimodales, y tanto la media como la desviación estándar se ven considerablemente alteradas por la presencia de valores extremos (atípicos).

El *box plot* muestra un mejor resumen de la distribución de los datos utilizando la posición relativa de ellos en lugar de los valores exactos. Este gráfico **no** refiere **la frecuencia** para cada valor o para cada categoría. Utiliza **los estadísticos de orden como son los cuartiles** y permite identificar **valores atípicos** (datos inusualmente grandes o sumamente pequeños) y comparar distribuciones.



Los estadísticos de orden consisten en organizar los datos en forma ascendente de acuerdo con su magnitud, para identificar valores tales como el máximo, el mínimo, la mediana o percentil 50, entre otros. Esto ya lo aprendiste en el tema de medidas de tendencia central, en particular para el cálculo de la mediana.

Retomando el ejemplo de los tiempos (en minutos) que te toma alistarte por las mañanas, los datos originales son los siguientes:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	43	52	39	44	40	31	44	35

Ahora, al ordenarlos de menor a mayor resulta lo siguiente:

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	43	44	44	52

■ Paso 1: Obtención del primer cuartil (Q_1)

Una vez ordenados los datos, se divide el total de datos en 4 partes iguales, llamados cuartiles, de tal manera que, del total de datos, o “n”, 25 % de ellos serán incluidos en el primer cuartil (Q_1). Por ejemplo, si tenemos 10 datos, cada una de las partes, llamadas cuartiles, tendrá 2.5 datos.

$$\text{Lugar que ocupa el primer cuartil} = \frac{n + 1}{4} = \frac{10 + 1}{4} = 2.75$$

A continuación encontrarás algunas reglas indispensables a considerar en el cálculo de los **cuartiles** (Q_1 , Q_2 y Q_3):

- **Regla 1:** Si el lugar o posición del cuartil es entero, el cuartil es igual al valor o dato que se encuentre en dicha posición. Si por ejemplo el tamaño de la muestra fuera $n=7$, el primer cuartil (Q_1) es igual al dato asociado con

$$\frac{n + 1}{4} = \frac{7 + 1}{4} = 2$$

Es decir, el valor que se encuentra en la posición 2 de los datos ordenados de menor a mayor.

- **Regla 2:** Si el lugar o posición del cuartil tiene una fracción de 0.5, el cuartil es igual a la medida que corresponde al promedio de las medidas correspondientes a los dos valores involucrados. Si por ejemplo el tamaño de la muestra fuera $n=9$, el primer cuartil (Q_1) es igual al dato asociado con

$$\frac{n + 1}{4} = \frac{9 + 1}{4} = 2.5$$

Es decir, el promedio obtenido de los datos ubicados en las posiciones 2 y 3 de los datos ordenados de menor a mayor.

- **Regla 3:** Si el lugar o posición del cuartil no es entero ni incluye un valor con fracción de 0.5, **se redondea** el resultado al entero más cercano (ya sea el inmediato anterior o posterior) y se selecciona el valor correspondiente a esa posición. Si por ejemplo el tamaño de la muestra fuera $n=10$, el primer cuartil (Q_1) es igual al dato asociado con $\frac{n+1}{4} = \frac{10+1}{4} = 2.75$, es decir, se redondea 2.75 a 3, y el valor que se encuentra en la posición 3 de los datos ordenados de menor a mayor será el valor de (Q_1).

Para nuestro ejemplo, la posición de Q_1 se obtiene:

$$\text{Lugar que ocupa el primer cuartil} = \frac{n+1}{4} = \frac{10+1}{4} = 2.75$$

Y, aplicando la regla 3, el Q_1 es la posición 3, cuyo valor es 35.

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	43	44	44	52

Para interpretar Q_1 diremos que en el 25 % de los días analizados, el tiempo que te tomó alistarte fue menor o igual a 35 minutos, y que en el 75 % de los días, te tomó un tiempo mayor o igual a 35 minutos.

■ Paso 2: Obtención del segundo cuartil (Q_2)

El segundo cuartil o Q_2 es igual a **la mediana** (también conocida como percentil 50). Retomando el procedimiento para calcularla, es el siguiente:

$$\text{Lugar que ocupa la mediana} = \frac{n + 1}{2}$$

n es el total de observaciones en la muestra.

El cálculo sería de la siguiente forma:

$$\text{Lugar que ocupa la mediana } (Q_2) = \frac{n + 1}{2} = \frac{10 + 1}{2} = 5.5$$

$$\text{Mediana } (Q_2) = \frac{39 + 40}{2} = 39.5$$

Para interpretar Q_2 diremos que en el 50 % de los días analizados, el tiempo que te tomó alistarte fue menor o igual a 39.5 minutos, y que en el otro 50 % de los días, te tomó un tiempo mayor o igual a 39.5 minutos.

■ Paso 3: Obtención del tercer cuartil (Q_3)

Para el cálculo del tercer cuartil (Q_3) se realiza un proceso similar a Q_1 , sin embargo la fórmula se modifica de la siguiente manera:

$$\text{Lugar que ocupa el tercer cuartil} = \frac{3(n+1)}{4} = \frac{3(10+1)}{4} = 8.25$$

Y, aplicando la regla 3, el Q_3 es la posición 8, cuyo valor es 44.

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	43	44	44	52

Para interpretar Q_3 diremos que en el 75 % de los días analizados, el tiempo que te tomó alistarte fue menor o igual a 44 minutos, y que en el 25 % de los días, te tomó un tiempo mayor o igual a 44 minutos.

Una vez teniendo tanto el Q_1 como el Q_3 , puedes calcular el rango intercuartílico. El **rango intercuartílico (RIQ)** mide la diferencia, en el centro de la distribución, entre el tercer cuartil (Q_3) y el primer cuartil (Q_1). El rango intercuartílico mide la **dispersión en el 50 % central de los valores**, y no es influenciado por los valores extremos. Además, el rango intercuartílico puede ser usado para determinar los datos atípicos o extremos (*outliers*). Dicho rango puede ser calculado de la siguiente manera:

$$\text{Rango intercuartílico} = Q_3 - Q_1$$

■ Paso 4: Cálculo de los bigotes del *box plot*

El término bigote, en el *box plot*, se refiere a las extensiones que salen de la caja. Cuando no existen valores atípicos, el bigote inferior será una línea que comienza en el dato mínimo y termina en Q_1 (donde comienza la caja), mientras que el bigote superior es una línea que inicia en Q_3 (donde termina la caja) y termina en el dato máximo. En principio, cada uno de los bigotes debe tener un largo “máximo” equivalente a 1.5 veces el largo de la caja.

Para determinar dónde inicial el **bigote inferior**, se compara el **valor mínimo** de los datos con el resultado de la fórmula $Q_1 - 1.5(Q_3 - Q_1)$ y la cantidad más cercana a Q_1 es la que marca el tamaño del bigote.

En nuestro ejemplo, quedaría de la siguiente manera:

$$Q_1 - 1.5(Q_3 - Q_1)$$

$$Q_1 - 1.5(\text{Rango intercuartílico})$$

$$35 - 1.5(44 - 35) = 21.5$$

Entonces, comparando el 21.5 con el dato mínimo que es 29, el bigote inferior empezará en 29, el cual es el valor más cercano a Q_1 que es 35.


De la misma forma, para determinar el **bigote superior**, se compara el **valor máximo** de los datos con el resultado de la fórmula $Q_3 + 1.5(Q_3 - Q_1)$ y la cantidad más cercana a Q_3 es la que marca el tamaño del bigote.

Para nuestro ejemplo, el procedimiento es como se muestra a continuación:

$$Q_3 + 1.5(Q_3 - Q_1)$$
$$44 + 1.5(44 - 35) = 57.5$$

Entonces, comparando el 57.5 con el dato máximo que es 52, el bigote superior terminará en 52, el cual es el valor más cercano a Q_3 que es 44.

Box plot



Finalmente, el resumen de los resultados es:

$$\mathbf{Mín} = \mathbf{29}$$

$$\mathbf{Q_1} = \mathbf{35}$$

$$\mathbf{Q_2} = \mathbf{39.5}$$


$$\mathbf{Q_3} = \mathbf{44}$$

$$\mathbf{Máx} = \mathbf{52}$$


Así, al tomar en cuenta esta información, el *box plot* quedaría de la siguiente manera:

Nota importante: Es común que, al realizar el *box plot* mediante algún software como Excel, Minitab, SPSS, etc., el valor de algunos de los cuartiles/percentiles no coincidan con el valor que te arroje los cálculos que acabas de realizar. Esto se debe a que los softwares, en sus algoritmos, realizan interpolaciones y no redondean (truncan) al entero correspondiente en los casos en los que la cantidad de datos es par.

Como un ejemplo de las diferencias que te puedes encontrar al graficar utilizando algún software especializado, a continuación verás el *box plot* realizado en Excel, en el cual notarás que no coincide el valor del cuartil 1 (Q_1) de 34 con el que tú obtuviste de 35 mediante la fórmula.



Por otro lado, utilizando los datos que previamente calculaste, el *box plot* queda de la siguiente manera:



Los resultados en la gráfica muestran que el tiempo mínimo requerido para alistarte es de 29 minutos, que el 25 % de las veces te toma entre 29 y 35 minutos (valor mínimo y Q_1 , respectivamente). Además que el 50 % de las ocasiones te lleva menos de 39.5 minutos (valor de Q_2 o mediana) alistarte, mientras que el otro 50 % de las veces te consume más de 39.5 minutos. De la misma manera, puedes observar que el 50 % central de las veces te lleva entre 35 y 44 minutos (valores de Q_1 y Q_3 , respectivamente), es decir, hay 9 minutos de diferencia, lo cual representa el rango intercuartílico.

Podrás ver que la línea de la mediana está casi en el centro de la caja, y que la mediana y la media son muy parecidas, lo cual habla de cierto grado de cercanía de la distribución hacia la simetría. Otro factor importante es que el tamaño del bigote inferior es de 6 minutos (35-29), mientras que el del bigote superior es de 8 minutos (52-44). Para que hubiese simetría perfecta, ambos bigotes tendrían que tener el mismo tamaño.

¿Qué crees que sucedería si aplicas este mismo procedimiento para la versión del problema en el que se incluye un dato atípico en los tiempos? Recordemos los datos:

Día	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	39	29	103	52	39	44	40	31	44	35

Posteriormente, al ordenarlos de menor a mayor, quedan de la siguiente manera:

Orden	1	2	3	4	5	6	7	8	9	10
Tiempo (min)	29	31	35	39	39	40	44	44	52	103

Dado que la cantidad de datos n sigue siendo 10, las posiciones de Q_1 , Q_2 y Q_3 serán las mismas. Sin embargo, el valor donde termina el bigote superior no será el mismo.

Para determinar el bigote superior, se compara el **valor máximo** de los datos con el resultado de la fórmula $Q_3 + 1.5(Q_3 - Q_1)$ y la cantidad más cercana a Q_3 es la que marca el tamaño del bigote.

Para nuestro ejemplo, el procedimiento es como se muestra a continuación:

$$Q_3 + 1.5(Q_3 - Q_1)$$
$$44 + 1.5(44 - 35) = 57.5$$

Entonces, comparando el 57.5, con el dato máximo que es 103, el 103 es considerado dato atípico. El bigote superior terminará en el dato inferior más cercano al 57.5, que en este caso es el dato de la posición 9, cuyo valor es 52.


$$\text{Mín} = 29$$

$$Q_1 = 35$$

$$Q_2 = 39.5$$

$$Q_3 = 44$$

$$\text{Máx} = 103$$




Los resultados en la gráfica muestran que el tiempo mínimo requerido para alistarte es de 29 minutos, que el 25 % de las veces te toma entre 29 y 35 minutos. Además que el 50 % de las ocasiones te lleva menos de 39.5 minutos alistarte, mientras que el otro 50 % de las veces te consume más de 39.5 minutos. De la misma manera, puedes observar que el 50 % central de las veces te lleva entre 35 y 44 minutos, es decir, hay 9 minutos de diferencia, lo cual representa el rango intercuartílico.

Podrás ver que la línea de la mediana está casi en el centro de la caja, y que la mediana y la media refleja el efecto del dato atípico sobre ella, son muy distintas. Esto habla de lejanía entre ellas y de la presencia de sesgo hacia la derecha (o positiva). Otro factor importante es que el tamaño del bigote inferior es de 6 minutos (35-29), mientras que el del bigote superior es de 8 minutos (52-44). Para que hubiese simetría perfecta, ambos bigotes tendrían que tener el mismo tamaño.

En este caso, el dato de los 103 minutos es representado con un asterisco, lo cual indica que es un dato atípico. Esto implica que debes analizar qué circunstancias provocaron que esa medición del tiempo se alejara tan considerablemente del resto de los días en los que realizaste mediciones. Si consideras que dichas circunstancias tienen poca probabilidad de volver a repetirse, podrás excluir ese dato atípico de tu análisis. Por el contrario, si crees que volverá a darse un valor así con cierta frecuencia, lo mejor será sí tomarlo en cuenta.


De forma resumida, la estructura de todo *box plot* resulta de la siguiente manera:

Introducción al análisis de datos: *Box plot*



Fuente: Simply Psychology, 2023

Ahora que has aprendido a realizar un *box plot*, es importante que comprendas su relación con la densidad de la curva (formada con los polígonos de frecuencias) para distintos tipos de distribución:






Donde: $X_{\min}$ -> valor mínimo, $X_{\max}$ -> valor máximo, Q_1, Q_2, Q_3 -> Cuartiles, X -> media, M_e -> mediana, M_o -> moda

Fuente: adaptado de Estadisticando, s.f.

De igual manera, la forma en que los datos están distribuidos en cada tipo de distribución, es la siguiente:

Resumen estadístico de 5 números

Relaciones entre el resumen de 5 números y el tipo de distribución

	Tipos de distribución		
Comparación	Sesgada hacia la izquierda	Simétrica	Sesgada hacia la derecha
			
La distancia entre el valor menor $X_{\min}$ y la mediana en contraste con la distancia entre la mediana y el valor mayor $X_{\max}$	La distancia entre el valor menor $X_{\min}$ y la mediana es mayor con la distancia entre la mediana y el valor mayor $X_{\max}$.	Las dos distancias son iguales.	La distancia entre el valor menor $X_{\min}$ y la mediana es menor con la distancia entre la mediana y el valor mayor $X_{\max}$.
La distancia entre el valor menor $X_{\min}$ y Q_1 en contraste con la distancia entre Q_3 y el valor mayor $X_{\max}$	La distancia entre el valor menor $X_{\min}$ y Q_1 es mayor la distancia entre la Q_3 y el valor mayor $X_{\max}$.	Las dos distancias son iguales.	La distancia entre el valor menor $X_{\min}$ y Q_1 es menor que la distancia entre la Q_3 y el valor mayor $X_{\max}$.
La distancia entre Q_1 y la mediana en contraste con la distancia entre la mediana y Q_3	La distancia entre Q_1 y la mediana es mayor que la distancia entre la mediana y la Q_3 .	Las dos distancias son iguales.	La distancia entre Q_1 y la mediana es menor que la distancia entre la mediana y Q_3 .

En resumen de 5 números para una variable cuantitativa está formado por: el **valor menor $x_{\min}$** , el **primer cuartil Q_1** , la **mediana Q_2** , el **tercer cuartil Q_3** y por el **valor mayor $x_{\max}$**

Fuente: Berenson, M., Levine, D., Szabat, K. y Stephen, D. (2017)

Recuerda que los cuartiles muestran que la distribución de los datos fue dividida en 4 partes. En una **distribución simétrica o de forma de campana**, la media y la mediana son iguales. Además, la longitud de la cola izquierda es igual a la de la cola derecha. Por otro lado, la mediana es la que divide a la caja en 2.

Cuando la distribución es **sesgada hacia la izquierda (asimétrica negativa)**, los pocos valores menores afectan a la media moviéndola hacia la cola izquierda. Esto significa que la mayor agrupación de los valores se encuentran en los valores mayores de la escala. El 75 % de todos los valores se encuentra a partir de Q_1 hasta el valor máximo.

En contraste, en la distribución **sesgada a la derecha (asimétrica positiva)**, la concentración de los valores se da en la parte inferior de la escala. Entonces, el 75 % de los valores se encuentra desde el valor mínimo y hasta Q_3 . Existe una larga cola derecha que contiene el 25 % de los valores más grandes, demostrando así la falta de simetría en el conjunto de datos.

Ahora que ya conoces los diferentes tipos de gráficas para representar tus variables, veamos, a través de un par de ejemplos, cómo podrías usarlas para analizar y resolver un problema.


Ejemplo

Deseas comparar los tiempos de espera en 2 bancos en el horario de comida. Los tiempos de espera (en minutos) de 15 clientes en cada banco son los siguientes:

Banco 1	4.21	5.55	3.02	5.13	4.77	2.34	3.54	3.2	4.5	6.1	0.38	5.12	6.46	6.19	3.79
Banco 2	9.66	5.9	8.02	5.79	8.73	3.82	8.01	8.35	10.49	6.68	5.64	4.08	6.17	9.91	5.47

Fuente: Berenson, M., Levine, D., Szabat, K., & Stephen, D. (2017)

La gerencia de ambos bancos busca implementar la política de que el tiempo típico de espera de un cliente sea de 5 minutos si acude en horario de comida. A continuación verás los *box plots* resultantes:



En el banco 1 la media es menor que la mediana, por lo que se interpreta que la distribución de los tiempos de espera es sesgada hacia la izquierda. Esto se confirma al observar que el bigote inferior es más largo que el bigote superior. Los valores inusuales o poco comunes están en los tiempos mínimos.

Por otra parte, en el banco 2, la media es mayor que la mediana, lo cual significa que la distribución de los tiempos de espera es sesgada hacia la derecha. Esto significa que hay algunos valores inusuales altos.

Con estos indicadores, es más posible que el banco 1 cumpla con la política deseada de que el tiempo promedio de espera sea 5 minutos, ya que sus valores de media y mediana son menores a 5 minutos. En contraste, en el banco 2, el 75 % de sus valores se encuentran por encima de 5 minutos de tiempo de espera, ya que $Q_1 = 5.64$ minutos.

Medidas de asociación entre dos variables

Relación entre variables categóricas

Con frecuencia en la toma de decisiones requieres comprender la **relación entre dos variables**, si es que existe. Cuando las variables son **categóricas** se utiliza la **tabulación cruzada o tabla de contingencia**, como lo vimos en el tema 3, y sus gráficos correspondientes son las gráficas de barras agrupadas y de barras apiladas. Los **indicadores** descriptivos para este tipo de casos **son porcentajes** obtenidos de la división de la frecuencia de cada celda con respecto al total.

Recordando el ejemplo del tema 3 sobre la encuesta en la que se les preguntó a 1,520 ciudadanos adultos “¿Se sienten abrumados con demasiada información en las redes?”, la información es la siguiente:

¿Abrumado?	Género		Total
	Hombre	Mujer	
Sí	134	170	304
No	651	565	1,216
Total	785	735	1,520

Entonces, calculando los porcentajes con respecto al total de 1,520 encuestados, el resultado es el siguiente:

¿Abrumado?	Género		Total
	Hombre	Mujer	
Sí	8.8 %	11.2 %	20 %
No	42.8 %	37.2 %	80 %
Total	51.6 %	48.4 %	100 %

Es importante notar que la suma de los porcentajes por renglón es el equivalente al total, es decir, $8.8 \% + 11.2 \%$ es igual al 20% que representa al total de personas que respondieron sí estar abrumados. Además, notarás que los respondientes fueron 51.6% hombres y 48.4% mujeres.

Este tipo de comparaciones en porcentaje revela que las mujeres están un poco más abrumadas que los hombres, ya que los porcentajes son 11.2% para las mujeres, contrastando con el 8.8% de hombres.

■ Relación entre variables continuas

Cuando las dos variables a analizar son variables continuas, aprendimos que la representación gráfica correspondiente es el diagrama de dispersión. Las mediciones numéricas para representar de manera más precisa, la relación entre dos variables cuantitativas se denomina análisis de correlación. El coeficiente de correlación brinda una medida cuantitativa de la fuerza de la relación entre dos variables.

Así como la varianza de una variable te indica cómo es la relación de los datos alrededor de la media muestral, la covarianza analiza la relación de la variable x con respecto a su media, y simultáneamente, de la variable y con relación a su respectiva media.

$$\text{Covarianza} = s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

s_{xy} representa a la covarianza de la muestra.

La letra griega Σ es el signo de sumatoria.

x_i representa cada observación de la variable x .

y_i representa cada observación de la variable y .

$\bar{x}$ representa la media de los datos de la variable x .

$\bar{y}$ representa la media de los datos de la variable y .

n el total de observaciones en la muestra.

En otras palabras, la **covarianza** es un valor que indica el grado de **variación conjunta** de dos variables cuantitativas aleatorias respecto a sus medias. Es importante resaltar que la **condición de aleatoriedad** de las variables implica que no se tiene control sobre ellas. Esta condición hace una **diferenciación importante entre los términos de correlación y regresión lineal**.

A continuación, podrás ver cómo la varianza, al elevarse al cuadrado, representa la relación de la variable consigo misma. Esto en contraste con la covarianza de representación conjunta o simultánea de dos variables.

Varianza	Covarianza
$\text{Var}(x) = s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / (n - 1) =$ $\sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x}) / (n - 1)$	$s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$

Cuando los datos son poblacionales la forma de calcular la covarianza sería:

$$\text{Covarianza poblacional } \sigma_{xy} = \sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y) / (N)$$

Al analizar la covarianza podría parecer que un valor positivo grande indica una relación lineal positiva sólida, y un valor negativo grande indica también una relación negativa sólida. Sin embargo, un problema con la **covarianza** como medida de solidez de una relación lineal estriba en que **su valor depende de las unidades de medida para x y y** . Para resolver esto, surge el coeficiente de correlación, el cual es una medida de la relación entre dos variables que no se ve afectada por las unidades de medición para x y y .

El coeficiente de correlación del punto momento de Pearson, nombrado así por su creador Karl Pearson en 1900, para los datos muestrales, conocido comúnmente de manera más simple como coeficiente de correlación muestral **se calcula al dividir la covarianza muestral entre el producto de la desviación estándar de x y la desviación estándar de y** .

$$\mathbf{r} = \frac{\text{Covarianza}(x,y)}{(\text{desviación estándar}_x)(\text{desviación estándar}_y)}$$

$$\mathbf{r} = \frac{s_{xy}}{s_x s_y}$$

$$\mathbf{r} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{}$$


Este coeficiente **describe la fuerza de la relación entre dos conjuntos de variables aleatorias en escala de intervalo o de razón**. Se designa con la letra **r** , y con frecuencia se le conoce **como r de Pearson** o coeficiente de correlación producto-momento. Puede adoptar cualquier valor de -1.00 a +1.00, inclusive.

Un coeficiente de correlación de -1.00 o bien de +1.00 indica una correlación lineal perfecta. Si no hay ninguna relación entre los dos conjuntos de variables, la **r** de Pearson es cero. Un coeficiente de correlación **r** cercano a 0, por ejemplo 0.08, indica que la relación lineal es muy débil.

Es importante resaltar que no se debe confundir la significancia estadística con la significancia práctica. Con valores de muestra muy grandes se puede obtener resultados estadísticamente significativos para valores pequeños de **r** . Además, para fines prácticos, cuando se trata de datos que se manejan por lo general en ciencias sociales, valores de **r** = 0.50 suelen considerarse útiles. En datos de física o de ciencias de la vida suelen encontrarse valores de **r** = 0.70 o más, en algunos casos mayores de 0.90. En las aplicaciones de negocios, los valores de **r** varían enormemente dependiendo de las características de cada aplicación.

En la siguiente imagen verás el nivel de asociación de las variables según el valor de correlación entre ellas:

Análisis Bi-variado: Correlación



¿Cómo se determina el coeficiente de correlación?

$$r = \frac{\text{Covarianza } (x,y)}{(\text{desviación estándar}_x)(\text{desviación estándar}_y)}$$

$$r = \frac{s_{xy}}{s_x s_y}$$


$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{s_x s_y}$$

Ejemplo 1

Una nevería de la ciudad lleva un registro de la cantidad de helado que venden con relación a la temperatura de cada día. Los datos que obtuvieron son los siguientes:

Temperatura (°C)	14.2	16.4	11.9	15.2	18.5	22.1	19.4	25.1	23.4	18.1	22.6	17.2
Venta del día (USD)	\$215	\$325	\$185	\$332	\$406	\$522	\$412	\$614	\$544	\$421	\$445	\$408

Una vez plasmados los datos en el diagrama de dispersión, el resultado es:



Fuente: adaptado de Disfruta las matemáticas, s.f

Como podrás ver en el diagrama de dispersión, sí se puede considerar que existe una fuerte correlación lineal entre ambas variables, ya que los puntos se encuentran muy cerca de la línea recta o de tendencia. Además, debido a que conforme aumenta la temperatura, también aumentan las ventas, dicha correlación es positiva o directa.

Ahora, procederemos a hacer el cálculo del coeficiente de correlación.

$$r = \frac{\text{Covarianza } (x,y)}{(\text{desviación estándar}_x)(\text{desviación estándar}_y)}$$

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}}$$

x y						
Temperatura (°C)	Venta del día (USD)	(Xi- Promedio)	(Yi- Promedio)	(Xi- Promedio) ²	(Yi- Promedio) ²	(Xi- Promedio) * (Yi- Promedio)
14.2	215	-4.48	-187.42	20.025625	35125.00694	838.6895833
16.4	325	-2.28	-77.42	5.175625	5993.340278	176.1229167
11.9	185	-6.78	-217.42	45.900625	47270.00694	1272.997917
15.2	332	-3.48	-70.42	12.075625	4958.506944	244.6979167
18.5	406	-0.18	-3.58	0.030625	12.84027778	-0.627083333
22.1	522	-3.43	-119.58	11.730625	14300.17361	409.5729167
19.4	412	0.72	9.58	0.525625	91.84027778	6.947916667
25.1	614	6.43	211.58	41.280625	44767.50694	1359.422917
23.4	544	4.73	141.58	22.325625	20045.84028	668.98125
18.1	421	-0.57	18.58	0.330625	345.3402778	-1068541667
22.6	445	3.93	42.58	15.405625	1813.340278	167.1395833
17.2	408	-1.48	5.58	2.175625	31.17361111	-8.235416667
Promedio	18.68	402.42	Suma	176.9825	174754.9167	5325.025
			Div entre n-1	16.08931818	15996.81061	484.0931818
			Raíz cuadrada	4.011149235	126.0428919	
			r	0.957506623		

Ahora, para medir la fuerza de la relación entre la Temperatura (°C), y las Ventas (USD), calculas el coeficiente de correlación correspondiente:

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}}$$

$$= \frac{484.0931818}{(4.011149235)(126.0428919)} = 0.9575$$

El signo positivo del valor de la correlación muestra que existe una relación directa entre las variables (como ya lo habías observado en el diagrama de dispersión). Además, el valor de la correlación, es decir, $r = +0.9575$, al ser un valor muy cercano al 1, indica que la asociación entre las variables es fuerte.

Si hay una relación fuerte (en este caso $r = 0.9575$) entre dos variables, es factible suponer que un aumento o una disminución en los grados de la temperatura sí causa un cambio en las ventas.


■ Ejemplo 2

De una muestra de 20 personas diferentes, se ha registrado su estatura y su coeficiente intelectual (se usa para medir la inteligencia de una persona). La información obtenida es la siguiente:

Estatura (cm)	189	170	157	195	176	185	167	178	149	188
Coeficiente intelectual	107	92	122	115	98	101	126	89	95	110

Estatura (cm)	201	163	197	177	154	184	173	165	158	171
Coficiente intelectual	101	113	96	118	106	132	104	119	85	117

Al plasmar la información en un diagrama de dispersión, el resultado es:



Fuente: adaptado de Probabilidad y Estadística.net

Al observar el diagrama de dispersión, no se observa ninguna relación, es decir, la correlación es nula. Esto como resultado del hecho de que los puntos están dispersos por todo el diagrama sin seguir ningún patrón. A esta formación de puntos se le conoce como “nube de puntos”. Notarás que la línea es casi horizontal, lo cual indica que, aunque cambie el valor de la estatura, no existe efecto sobre el valor del coeficiente intelectual. En estos casos, la línea horizontal resultante es el valor promedio de la variable en el eje vertical (Y).

Como siguiente paso, procederemos a hacer el cálculo del coeficiente de correlación.

$$r = \frac{\text{Covarianza } (x,y)}{(\text{desviación estándar}_x)(\text{desviación estándar}_y)}$$

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}}$$



x y						
Estatura (cm)	Coficiente Intelectual	(Xi-Promedio)	(Yi-Promedio)	(Xi-Promedio) ²	(Yi-Promedio) ²	(Xi-Promedio) * (Yi-Promedio)
189	107	14.05	-0.47	197.4764543	0.224376731	-6.656509695
170	92	-4.95	-15.47	24.47645429	239.434903	76.55401662
157	122	-17.95	14.53	322.1080332	211.0138504	-260.7091413
195	115	20.05	7.53	402.1080332	56.64542936	150.9224377
176	98	1.05	-9.47	1.108033241	89.75069252	-9.972299169
185	101	10.05	-6.47	101.0554017	41.90858726	-65.07756233
167	126	-7.95	18.53	63.16066482	343.2243767	-147.2354571
178	89	3.05	-18.47	9.318559557	341.2770083	-56.3933518
149	95	-25.95	-12.47	673.265928	155.5927978	323.6592798
188	110	13.05	2.53	170.3711911	6.382271468	32.97506925
201	101	26.05	-6.48	678.7396122	41.90858726	-168.6565097
163	113	-11.95	5.53	142.7396122	30.5401662	-66.02493075
197	96	22.05	-11.47	486.3185596	131.6454294	-253.0249307
177	118	2.05	10.53	4.213296399	110.8033241	21.6066482
154	106	-20.95	-1.47	438.7922438	2.171745152	30.86980609
184	132	9.05	24.53	81.9501385	601.5401662	222.0277008
165	119	-9.95	11.53	98.9501385	132.8559557	-114.6565097
158	85	-16.95	-22.47	287.2132964	505.066482	380.8698061
171	117	-3.95	9.53	15.58171745	90.75069252	-37.69387812
Promedio	174.95	107.47	Suma	4198.947368	3132.836842	53.47368421
				Div entre n-1	233.2748538	174.0409357
				Raíz cuadrada	15.273338	13.19245753
				r	0.014743749	

Ahora, para medir la fuerza de la relación entre la Estatura (cm), y Coeficiente intelectual, calculas el coeficiente de correlación correspondiente:

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}} \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}}}$$

$$= \frac{2.970760234}{(15.273338)(13.19245753)} = 0.0147$$

El valor de $r = 0.0147$, al ser cercano a 0, indica que no existe una relación lineal entre las dos variables. Esto es, que la estatura no tiene influencia sobre el coeficiente intelectual de una persona.

Para los datos poblacionales la letra utilizada para la correlación es ρ_{xy} , Ro.


$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

Para realizar este cálculo mediante Excel puedes utilizar las funciones de COVARIANZA.M(matriz1, matriz2); DESVEST.M(número₁, ..., número_n) y COEF.DE.CORREL(matriz1, matriz2).

Si hay una relación fuerte (sea 0.91) entre dos variables, es factible suponer que un aumento o una disminución en una variable causa un cambio en la otra. Por ejemplo, se puede demostrar que el consumo de chocolate en Suiza y la cantidad de premios Nobel de ese país tienen una correlación fuerte. Sin embargo, esto no indica que un aumento del consumo de chocolates hizo crecer la cantidad de premios Nobel recibidos.

Las relaciones de este tipo se denominan **correlaciones espurias**. Lo que se puede concluir cuando se tienen dos variables con fuerte correlación es que hay una relación o asociación entre ambas variables, no que un cambio en una ocasiona un cambio en la otra. Este concepto, en otras palabras, te dice que **casualidad no es lo mismo que causalidad**.

Debido a que el coeficiente de correlación mide sólo la fuerza de la relación lineal entre dos variables cuantitativas, es posible que tenga **un valor cercano a cero, sugiriendo que no existe relación lineal** cuando la relación entre dos variables no es lineal. Por ejemplo, el siguiente diagrama de dispersión te muestra la relación entre la temperatura exterior y el número de ausentes en una empresa:



Y su correspondiente cálculo del coeficiente de correlación es:

x y						
Temperatura (°C)	Ausentes	(Xi- Promedio)	(Yi- Promedio)	(Xi- Promedio) ²	(Yi- Promedio) ²	(Xi- Promedio) * (Yi- Promedio)
10.00	8.00	-29.40	2.30	864.36	5.29	-67.62
20.00	7.00	-19.40	1.30	376.36	1.69	-25.22
25.00	5.00	-14.40	-0.70	207.36	0.49	10.08
30.00	4.00	-9.40	-1.70	88.36	2.89	15.98
40.00	2.00	0.60	-3.70	0.36	13.69	-2.22
45.00	3.00	5.60	-2.70	31.36	7.29	-15.12
50.00	5.00	10.60	-0.70	112.36	0.49	-7.42
55.00	6.00	15.60	0.30	243.36	0.09	4.68
59.00	8.00	19.60	2.30	384.16	5.29	45.08
60.00	9.00	20.60	3.30	424.36	10.89	67.98
Promedio	39.40	5.70	Suma	2732.4	48.1	26.2
Div entre n-1				303.6	5.344444444	2.381818182
Raíz cuadrada				17.42412121	2.311805451	
r				0.059129804		

El coeficiente de correlación es 0.0591, y es cercano a cero. Éste indica que no existe relación lineal entre las dos variables. Sin embargo, el diagrama de dispersión proporciona una sólida evidencia visual de que existe una relación no lineal. Es decir, podemos ver que a medida que aumenta la temperatura exterior, el número de ausentes aumenta, de la misma manera que cuando baja mucho la temperatura. En resumen, **una correlación cercana a cero puede indicar que la relación lineal propuesta no es la indicada, sin que esto signifique que no existe una relación, de otro tipo, entre las variables.**

| Glosario

En esta lectura revisaste una serie de conceptos que tal vez no conocías, así que preparamos este glosario con las definiciones claves para que puedas revisarlas y tomar los apuntes necesarios.

- **Análisis de correlación:** Las mediciones numéricas para representar de manera más precisa, la relación entre dos variables cuantitativas.
- **Coeficiente de asimetría:** Mide el sesgo en una distribución. indica si el número de elementos a la izquierda de la media aritmética es el mismo que la cantidad de observaciones del lado derecho. Esta medida hace que no sea necesario hacer la gráfica para observar la distribución de los datos.
- **Coeficiente de correlación de Pearson:** Medida de la asociación lineal entre dos variables cuantitativas que toma los valores entre - 1 y + 1. Los valores cercanos a + 1 indican una relación lineal positiva sólida; los valores cercanos a - 1 indican una relación lineal negativa sólida, y los valores cercanos a cero, la ausencia de una relación lineal.

- **Coeficiente de correlación de Spearman:** Medida de la asociación lineal entre dos variables cualitativas que toma los valores entre - 1 y + 1. Los valores cercanos a + 1 indican una relación lineal positiva sólida; los valores cercanos a - 1 indican una relación lineal negativa sólida, y los valores cercanos a cero, la ausencia de una relación lineal.
- **Coeficiente de variación:** Medida de variabilidad relativa calculada al dividir la desviación estándar entre la media y multiplicar por 100.
- **Covarianza:** Medida de la asociación lineal entre dos variables. Los valores positivos indican una relación positiva; los valores negativos indican una relación negativa.
- **Cuartiles:** Los percentiles 25, 50 y 75, conocidos como primer cuartil, segundo cuartil (mediana) y tercer cuartil, respectivamente. Los cuartiles se usan para dividir un conjunto de datos en cuatro partes, con cada parte conteniendo aproximadamente 25 % de los datos.
- **Desviación estándar:** Medida de variabilidad que se obtiene al calcular la raíz cuadrada positiva de la varianza.
- **Diagrama de dispersión:** Presentación gráfica de la relación entre dos variables cuantitativas. Una variable se muestra en el eje horizontal y la otra en el eje vertical.
- **Dispersión:** Es el grado en que los datos numéricos tienden a extenderse alrededor de un valor medio, mostrando qué tan parecidos, o no, son los datos entre sí.
- **Observación atípica:** Valor de dato inusualmente pequeño o inusualmente grande.

- **Parámetro poblacional:** Valor numérico utilizado como una medida de resumen para una población (por ejemplo, la media poblacional, la varianza poblacional, σ^2 , y la desviación estándar de la población, σ).
- **Percentil:** Valor tal que por lo menos p por ciento de las observaciones es menor o igual que este valor, y como mínimo $(100 - p)$ por ciento de las observaciones son mayores o iguales que este valor. El percentil 50 es la mediana.
- **Rango intercuartílico o intercuartil (RIC):** Medida de variabilidad definida como la diferencia entre el tercer y el primer cuartiles.
- **Regla empírica (distribución normal):** Se usa para calcular el porcentaje de valores de datos que deben estar dentro de una, dos y tres desviaciones estándar de la media para los datos que exhiben una distribución con forma de campana.
- **Resumen de cinco números:** Técnica de análisis exploratorio de datos que usa cinco números para resumir los datos: valor menor, primer cuartil, mediana, tercer cuartil y valor más grande.
- **Sesgo:** Medida de la forma de una distribución de datos. Los datos sesgados a la izquierda dan como resultado un sesgo negativo; una distribución de datos simétrica genera un sesgo de cero, y los datos sesgados a la derecha producen un sesgo positivo.
- **Tabulación cruzada o tabla de contingencia:** Son utilizadas para comprender la relación o asociación entre dos variables categóricas, si es que existe.


De acuerdo a tu perfil

Cuando deseas analizar dos variables, tendrás las opciones de una tabla cruzada para variables categóricas y del análisis de correlación para variables continuas. Analizamos que el valor del coeficiente de correlación " r ", si bien va de -1 a +1, en cada área de aplicación puede variar el valor del coeficiente de correlación " r " a partir del cual se considera significativo o relevante. ¿Qué valor del coeficiente de correlación " r " consideras significativo para el área en la que desempeñas tu trabajo?

Veamos algunos ejemplos de variables aplicadas a distintas áreas y perfiles.

Comercial

En un estudio realizado en Colombia, en el cual se analiza la correlación entre el tamaño de un apartamento y su precio (en millones de pesos colombianos, COP). Además, se calculó el coeficiente de correlación, el cual resultó en un valor de 0.8582. Esto muestra que existe una relación fuerte entre el tamaño del apartamento y su precio. A continuación, el diagrama de dispersión resultante:




Fuente: adaptado de Hernández F. y Usuga, O. (2023) Manual de R.

Podrás notar que el diagrama muestra que, a mayor tamaño del apartamento, la variación en el precio es mayor. ¿Cómo podrías interpretar esta diferencia en la variabilidad?

Estudios de mercado

Una compañía de telefonía celular realiza un estudio para determinar la cantidad semanal de mensajes de texto que envían sus clientes por rangos de edades con el objetivo de analizar los planes de servicio que actualmente ofrecen. El resultado se muestra en el siguiente *box plot*:




Fuente: adaptado de Facer, C. (s.f.). DisplayR.

Como podrás observar, a medida que aumenta la edad del cliente, disminuye la mediana de la cantidad de mensajes que envía en una semana. De igual manera, la dispersión se reduce notablemente a partir de los 35 años de edad.

Administrativo

Se ha realizado un estudio para analizar la correlación entre la edad de una persona y el salario que percibe. El gráfico resultante es el siguiente:




Fuente: adaptado de bigml, 2015

El coeficiente de correlación obtenido es de $r = 0.832282$, lo cual nos indica que sí existe una relación fuerte entre la edad de una persona y el salario que recibe.

Salud

El siguiente *box plot* muestra la duración (en días) de la estancia en el hospital de 50 pacientes, con y sin diabetes, para un procedimiento ortopédico de cirugía de rodilla entre Julio de 2010 y junio de 2011 en hospitales del Reino Unido:




Fuente: adaptado de ResearchGate, s.f.

No se encontró una diferencia significativa entre los dos grupos ya que la cantidad de días de estancia son muy similares en cuanto a sus medianas.

Banquero

La rentabilidad sobre el patrimonio (ROE), entendida como la utilidad neta anualizada sobre el patrimonio contable promedio de las Instituciones de Microfinanzas (IMFs) de Perú en los últimos 16 años, particularmente de las Cajas Municipales de Ahorro y Crédito (CMACs).




Fuente: adaptado de Candia, G., 2017

En el anterior gráfico puedes observar un ascenso de las gráficas de cajas hasta el 2003, lo que denota un aumento de la mediana en esos tres primeros años, de más del 26 % en el 2001 a un poco menos del 33 % en el 2003, además, este crecimiento de la ROE estuvo acompañado por una menor dispersión del RIQ (rango intercuartil), de 2.61 en el 2001 a 1.67 en el 2003, lo que quiere decir que las diferencias en las rentabilidades financieras, en un contexto de crecimiento promedio de todas las CMACs, fue reduciéndose. Sin embargo, al año siguiente, no solo aumentó la dispersión en relación a los tres años anteriores, el RIQ aumentó a 3.32 en el 2004 el doble del experimentado en el 2003, sino que también la mediana se derrumbó en más de 5,5 pp con respecto al año anterior, más que la media que lo hizo en 4,8 pp, lo que aglutinó la distribución de las rentabilidades en los valores inferiores, es decir, el 25 % de los datos que se encuentran entre Q1 y Q2 están más próximos entre sí, que los datos de la misma proporción que se encuentran entre el Q2 y el Q3, sesgando la distribución hacia la derecha, además de que el bigote superior es más largo que el inferior, en concreto, en el 2004 las rentabilidades entre las CMACs además de caer, fueron mayormente diferentes entre ellas en relación a años anteriores.

Vida diaria

En el siguiente gráfico se muestra la cantidad de puntos por partidos de 5 jugadores de la NBA. En él puedes ver cuál es el jugador que mete más puntos, o cuál es el más constante:



Fuente: adaptado de Ollé, J. (s.f.). Conceptos claros

Principalmente podrás observar que Carmelo Anthony, a pesar de presentar la mayor variabilidad de puntos anotados, su primer cuartil (el 25 % de las veces) está en un nivel similar al tercer cuartil (el 75 % de las veces) del resto de los jugadores.

Para que quede más claro

En este tema estudiaste cómo un conjunto de datos numéricos puede ser representado por estadísticas que miden las propiedades de tendencia central, variabilidad y forma. En los negocios, las estadísticas descriptivas que hemos estudiado en este tema son frecuentemente incluidas en reportes que son generados de forma periódica.

El volumen de información disponible en los principales medios digitales e impresos ha causado mucho escepticismo en las personas sobre la veracidad de los datos. Cuando lees información que contiene estadísticas descriptivas debes mantener en mente la famosa frase de Benjamín Disraeli: “Hay tres tipos de mentiras: las mentiras, las malditas mentiras y las estadísticas”.


Por ejemplo, al examinar las estadísticas requieres comparar la media y la mediana. ¿Son similares o muy diferentes? ¿O solamente la media es utilizada? Las respuestas a estas preguntas te pueden ayudar a determinar si los datos son sesgados o simétricos, y si la mediana puede ser mejor medida de tendencia central que la media. Además, debes observar si la desviación estándar o el rango intercuartil han sido incluidos en el análisis. Sin esto, es imposible determinar la cantidad de variación que existe en los datos.

En la relación de dos variables debes de considerar siempre su naturaleza, ya sea categórica o cuantitativa. Una variable cuantitativa puede ser organizada en clases, y formar su distribución de frecuencias. De esta forma podrás compararla con una variable categórica mediante una tabla cruzada.

Consideraciones éticas surgen cuando debes decidir qué resultados incluir en un reporte. Es indispensable incluir tanto los buenos como los malos resultados.

Además, en todas las presentaciones debes reportar resultados que sean justos, objetivos y de forma imparcial. El comportamiento no ético ocurre cuando intencionalmente no reportas resultados a favor o en contra de una posición particular.

Medidas numéricas




Fuente: adaptado de Berenson, M., Levine, D. Szabat, K., Stephen, D. (2017)

Medidas de forma: sesgo y curtosis

Sesgo

- Medida de la forma de una distribución de datos
- Si los datos tienen una **distribución simétrica**, entonces el sesgo = 0



$$\text{coeficiente de asimetría} = \frac{\frac{1}{n} \sum_i^n (x_i - \bar{x})^3}{s^3}$$


Curtosis

- Mide la “**cantidad de pico**” que tiene una distribución.
- Generalmente se toma como referencia la **curtosis** de la distribución normal que es igual a 3.

$$\text{curtosis} = \frac{\frac{1}{n} \sum_i^n (x_i - \bar{x})^4}{s^4}$$

Leptocúrtica


$$K > 3$$



Valores mayores de 3 tienden a curvas leptocúrticas

Mesocúrtica


$$K = 3$$



La referencia es la distribución normal que tiene una curtosis de 3. En algunos paquetes estadísticos la referencia es 0.

Platicúrtica

$$K < 3$$



Valores menores de 3 tienden a curvas platicúrticas

Detección de observaciones atípicas Valor Z vs. Box plot

El **valor z** o **valor estandarizado** es una medida de posición relativa que ayuda a determinar a qué **distancia de la media** se encuentra un valor determinado en **términos de desviaciones estándar**.

$$\text{Valor } z = z = \frac{x_i - \bar{x}}{s}$$

z_i cantidad de desviaciones estándar que la observación x_i tiene con respecto a la media.


x_i representa cada observación.

$\bar{x}$ representa la media de los datos.

s es la desviación estándar de la muestra.

Una observación atípica cualquier valor con una puntuación z menor que -3 o mayor que +3

El **box plot** es un gráfico que muestra un resumen de la distribución de los datos utilizando la **posición relativa** (mediante cuartiles) de ellos en lugar de los valores exactos.



Análisis de relación de dos variables: Tablas cruzadas vs análisis de correlación

Variables categóricas

Variables continuas

Tabla de contingencia o tabla cruzada

Variable 1	Variable 2					
	1	2	3	...	c	Total
1	n_{11}	n_{12}	n_{13}	...	n_{1c}	$n_{1.}$
2	n_{21}	n_{22}	n_{23}	...	n_{2c}	$n_{2.}$
3	n_{31}	n_{32}	n_{33}	...	n_{3c}	$n_{3.}$
...	...	...	...	...	...	...
...	...	...	...	...	...	...
r	n_{r1}	n_{r2}	n_{r3}	...	n_{rg}	$n_{r.}$
Total	$n_{.1}$	$n_{.2}$	$n_{.3}$	...	$n_{.g}$	n

n_{ij} observaciones que cumplen con la característica del nivel de la variable simultáneamente con la característica del nivel de la variable j


Los indicadores descriptivos para este tipo de casos **son porcentajes** obtenidos de la división de la frecuencia de cada celda con respecto al total.

Coefficiente de correlación (r)

$$r = \frac{\text{Covarianza } (x,y)}{(\text{desviación estándar}_x)(\text{desviación estándar}_y)}$$

$$r = \frac{S_{xy}}{S_x S_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / (n-1)}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 / (n-1)} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 / (n-1)}}$$

La letra griega Σ es el signo de sumatoria. x_i , y_i representa cada observación de la variable x ó y .
 $\bar{x}$, $\bar{y}$ representa la media de los datos de la variable x ó y .
 n el total de observaciones en la muestra.
 S_{xy} es la covarianza de la muestra



En práctica, los valores significativos del coeficiente de correlación r varían dependiendo de las características de cada área de aplicación (ciencias sociales, negocios, física, etc.).

Resumen estadístico de 5 números

Relaciones entre el resumen de 5 números y el tipo de distribución

	Tipos de distribución		
Comparación	Sesgada hacia la izquierda	Simétrica	Sesgada hacia la derecha
La distancia entre el valor menor $X_{\min}$ y la mediana en contraste con la distancia entre la mediana y el valor mayor $X_{\max}$	La distancia entre el valor menor $X_{\min}$ y la mediana es mayor con la distancia entre la mediana y el valor mayor $X_{\max}$.	Las dos distancias son iguales.	La distancia entre el valor menor $X_{\min}$ y la mediana es menor con la distancia entre la mediana y el valor mayor $X_{\max}$.
La distancia entre el valor menor $X_{\min}$ y Q_1 en contraste con la distancia entre Q_3 y el valor mayor $X_{\max}$	La distancia entre el valor menor $X_{\min}$ y Q_1 es mayor que la distancia entre Q_3 y el valor mayor $X_{\max}$.	Las dos distancias son iguales.	La distancia entre el valor menor $X_{\min}$ y Q_1 es menor que la distancia entre Q_3 y el valor mayor $X_{\max}$.
La distancia entre Q_1 y la mediana en contraste con la distancia entre la mediana y Q_3	La distancia entre Q_1 y la mediana es mayor que la distancia entre la mediana y Q_3 .	Las dos distancias son iguales.	La distancia entre Q_1 y la mediana es menor que la distancia entre la mediana y Q_3 .

En resumen de 5 números para una variable cuantitativa está formado por: el **valor menor $x_{\min}$** , el **primer cuartil Q_1** , la **mediana Q_2** , el **tercer cuartil Q_3** y por el **valor mayor $x_{\max}$**

Bibliografía

En caso de que desees consultar alguna de las referencias disponibles en internet, copia y pega la liga en tu navegador de preferencia.

Anderson, S. W. (2019). *Estadística para negocios y economía*. Ciudad de México: Cengage Learning Editores.

Berenson, M., Levine, D., Szabat, K., & Stephen, D. (2017). *Basic Business Statistics, Concepts and Applications. [Estadísticas Empresariales Básicas, Conceptos y Aplicaciones]*. New York: Pearson Education.

Charles Henry Brase, C. P. (2019). *Estadística Básica*. Ciudad de México: Cengage Learning Editores.

Huff, D. (1954). *How to Lie with Statistics. [Cómo mentir con estadísticas]*. New York - London: W.W. Norton & Company.