




Desigualdad de Chebyshev

La desigualdad de **Chebyshev**, es un **teorema** utilizado en estadística, **que permite hacer afirmaciones acerca de la proporción del total de datos que estará dentro de un rango específico de desviaciones estándar con respecto a la media.**

Una de las ventajas que ofrece este teorema es que se aplica a cualquier conjunto de datos sin importar su forma de distribución.



La fórmula general de este teorema es:

$$P(\mu - k\sigma \leq X \leq \mu + k\sigma) \geq 1 - \frac{1}{K^2}$$

De acuerdo con este teorema para $z = 2, 3$ y 4 desviaciones estándar se tienen:

- Por lo menos 0.75, o 75 %, de los valores de los datos deben estar dentro de $z = 2$ desviaciones estándar de la media.
- Al menos 0.89, o 89 %, de los valores deben estar dentro de $z = 3$ desviaciones estándar de la media.
- Por lo menos 0.94, o 94 %, de los valores deben estar dentro de $z = 4$ desviaciones estándar de la media.

■ Regla empírica

Cuando en las aplicaciones prácticas los conjuntos de datos muestran una **forma de campana**, se aplica **la regla empírica** de la siguiente forma:

- Cerca de **68 %** de los valores de los datos se encontrarán a no más de **una desviación estándar** desde la media.

- Aproximadamente **95 %** de los valores de los datos se encontrarán a no más de **dos desviaciones estándar** desde la media.
- **Casi todos los valores** de los datos estarán a no más de **tres desviaciones estándar** de la media.

Imagina que quieres saber cómo se distribuye el ingreso de tus clientes alrededor del ingreso promedio. Pudiera ser que exista la misma cantidad de clientes con ingresos bajos que altos. O tal vez hay muchos clientes con ingresos altos y pocos con ingresos bajos, o viceversa, muchos clientes con ingresos bajos y pocos clientes con ingresos altos.

En el ejemplo, lo expuesto quiere decir que si se cumpliera el comportamiento de una **distribución normal**:

- El **68 %** de tus clientes tienen ingresos en un rango que está a una distancia de **una desviación estándar** por arriba y por debajo de la media.
- El **95 %** de tus clientes tienen ingresos en un rango que está a una distancia de dos desviaciones estándar por arriba y por debajo de la media.
- Y, aproximadamente, todos tus clientes tienen ingresos en un rango que está a una distancia de tres desviaciones estándar por arriba y por debajo de la media.

En el caso de no cumplirse el comportamiento de una distribución normal, es decir, que existiera sesgo o una curtosis diferente a 3, entonces:

- Por lo menos el **75 %** de tus clientes tienen ingresos en un rango que está a dos desviaciones estándar de distancia, por arriba y por abajo, con respecto a la media.
- Y, en un rango de tres desviaciones estándar de ingresos, por encima y por debajo del ingreso medio, estarían por lo menos el **89 %** de tus clientes.

De forma resumida, veamos la siguiente imagen:

Sea X una variable aleatoria con media μ y desviación estándar σ .

Se cumple la **ecuación de Chebyshev** sin importar la forma de distribución de los valores.

$$P(\mu - k\sigma \leq X \leq \mu + k\sigma) \geq 1 - \frac{1}{K^2}$$

Intervalo	Desigualdad de Chebyshev Para cualquier conjunto de datos	Regla empírica Para conjuntos de datos forma campana
$\mu \pm 1\sigma$		$\approx 68 \%$
$\mu \pm 2\sigma$	$\geq 75 \%$	$\approx 95 \%$
$\mu \pm 3\sigma$	$\geq 89 \%$	$\approx 100 \%$

Entonces, ¿en qué casos podemos utilizar el teorema de Chebyshev?

Retomando el caso donde tienes un sitio web y quieres hacer una campaña publicitaria. Imagina que tienes un registro con el tiempo en que permaneció cada visitante dentro del sitio hasta que realizó una compra, de esta forma puedes darte una idea del rango del tiempo que le lleva a un cliente antes de realizar la compra, y así tener un referente para futuras campañas.

Los tiempos, en minutos, recopilados de 50 clientes, se muestran a continuación:

19.77	6.83	38.82	20.08	6.97
47.91	32.68	36.39	53.6	17.23
33.06	29.07	12.67	24.22	34.54
20.24	6.93	6.84	27.73	24.9
38.27	6.75	13.52	69.04	25.21
65.68	13.4	10.87	54.74	45.53
13.98	30.76	11.48	79.78	16.16
12.52	42.62	7.64	72.44	7.87
29.78	7.57	26.82	17.57	68.44
36.96	62.01	10.45	5.75	56.95

Ahora lo podemos resolver en pasos.

■ Paso 1

Lo primero que debes de calcular es la media y la desviación estándar de los datos. Los resultados muestran que la media es de 29.22 minutos y la desviación estándar es de 20.50 minutos.

Esto nos lleva a calcular el primer intervalo: a 29.22 le sumamos y le restamos 20.50, esto resulta en un intervalo de 8.72 a 49.73 minutos. Ahora lo que debes hacer es contar cuántos datos, del total de 50, se encuentran en este intervalo. Al hacerlo, tendrás que 32 datos se encuentran en el intervalo, el equivalente a decir que el 64 % ($32 / 50 * 100$).

■ Paso 2

El siguiente paso, es calcular el segundo intervalo. Para esto, es necesario multiplicar por 2 la desviación estándar. Es decir, $2 * 20.50$, lo que da como resultado 41. Ahora, a la media de 29.22 le sumas y le restas esta cantidad. Al hacerlo **el intervalo resultante es de -11.79 a 70.22 minutos**.

Quizá ante este resultado te preguntes: ¿cómo puede ser un valor negativo al hablar de tiempo? El valor negativo **sólo refleja que la variabilidad es grande**, y lo que hay que comprender de forma práctica es que el intervalo empezará en cero.

Al contar los valores en el conjunto de datos que se encuentran en este intervalo, resulta que 48 de los 50 cumplen con estos tiempos. En términos porcentuales es equivalente a decir que el 96 % ($48 / 50 * 100$) del total de datos está a dos desviaciones estándar con respecto a la media.

■ Paso 3

Por último, en el tercer intervalo se calcularán los datos que están a tres desviaciones estándar, por lo que debes multiplicar $3 * 20.50$, que resulta en 61.50, y a la media de 29.22 le sumas y le restas 61.50. El intervalo resultante tiene como límite inferior -32.29 y como límite superior 90.72 minutos. Al tratarse de tiempo, redondeamos el límite inferior a cero, ya que sabemos que no tiene sentido real utilizar valores negativos.

Si observas cuántos datos se encuentran en este tercer intervalo, verás que son todos, es decir, el 100 %.

Para que puedas observar los datos que acabas de obtener de forma condensada, revisa la siguiente tabla:

Media	Desv. estándar		Límites inferiores	Límites superiores	Cantidad	Porcentaje (%)
29.22	20.50	1	8.72	49.73	32	64
		2	-11.79	70.22	48	96
		3	-32.29	90.72	50	100

Estos resultados de los intervalos de tiempo te dicen que **tu nicho de mercado no está orientado a las compras impulsivas**, sino que les lleva hasta más de una hora y media de análisis para tomar la decisión de compra.

Ahora sigamos con el análisis estadístico aplicando el Teorema de Chebyshev.

Dado que el teorema nos dice que para datos en forma de campana darían como resultado el 68 %, el 95 % y el 100 % en los intervalos de una, dos, o tres desviaciones estándar con respecto a la media. ¿Crees que 68 vs 64, 95 vs 96 y 100 vs 100, nos dan una idea al estar muy cerca de los valores referente de que los datos tienen forma de campana? Si estás pensando en decir sí, lo cierto es que sin haber analizado previamente otros indicadores, no es posible tomar una decisión.



Vamos entonces a generar más indicadores que nos ayuden a tener un panorama real de cómo se distribuyen los datos:

Aplicación

Considera la siguiente muestra aleatoria del tiempo (min) para hacer una compra.



19.77	6.83	38.82	20.08	6.97
47.91	32.68	36.39	53.6	17.23
33.06	29.07	12.67	24.22	34.54
20.24	6.93	6.84	27.73	24.9
38.27	6.75	13.52	69.04	25.21
65.68	13.4	10.87	54.74	45.53
13.98	30.76	11.48	79.78	16.16
12.52	42.62	7.64	72.44	7.87
29.78	7.57	26.82	17.57	68.44
36.96	62.01	10.45	5.75	56.95

Intervalo	Para cualquier conjunto de datos	Para conjuntos de datos forma campana
$\mu \pm 1\sigma$		$\approx 68 \%$
$\mu \pm 2\sigma$	$\geq 75 \%$	$\approx 95 \%$
$\mu \pm 3\sigma$	$\geq 89 \%$	$\approx 100 \%$

Media	Desv. estándar		Límites inferiores	Límites superiores	Cantidad	Porcentaje (%)
29.22	20.50	1	8.72	49.73	32	64
		2	-11.79	70.22	48	96
		3	-32.29	90.72	50	100

Vamos entonces a generar más indicadores que nos ayuden a tener un panorama real de cómo se distribuyen los datos:

Medidas de tendencia central y dispersión							Tiempo (min.)				
50 registros	29.22 media	25.05 mediana	ND moda	12.26 1er cuartil	39.77 3er cuartil	5.75 mínimo	79.78 máximo	20.50 SD	70.17 CV	0.83 sesgo	-0.27 curtosis



Cuando observas los datos a través de los gráficos (histograma y *box plot*), puedes ver cómo en el *box plot*, que muestra los datos ordenados de menor a mayor y divididos en cuartiles, la diferencia de tamaños entre los bigotes inferior y superior **muestran la existencia de sesgo, es decir, se alejan del comportamiento campana.**

De la misma forma, el histograma muestra que la mayor cantidad de datos se encuentran concentrados en las primeras dos clases o intervalos. **Esto muestra también el sesgo.**

Ahora veamos el reflejo del sesgo en los indicadores de tendencia central y de forma. El cálculo del sesgo da como resultado 0.83, que se aleja de 0, que es el valor que esperarías en una distribución simétrica.

Además, las diferencias entre los valores de la media y la mediana, que son respectivamente 29.22 y 25.05, también muestran que el aumento en el valor de la media se debe a la presencia de algunos tiempos grandes que hicieron que la media se alejara de la mediana.

Te estarás preguntando, entonces ¿cómo me ayuda el teorema de Chebyshev a cuantificar los tiempos de mis clientes?

Recuerda que el Teorema de Chebyshev utiliza conjuntamente las medidas de tendencia central (la media), dispersión (la desviación estándar) y forma (distribución normal o no) para así tener una completa visión del comportamiento de la variable bajo análisis.

Dado que ya tienes claro la presencia de sesgo en la distribución de los tiempos de compra, deberás interpretar los intervalos de la siguiente forma:

- Por lo menos el 75 % de los clientes toman una decisión en el rango de 0 a 70.22 minutos (recuerda el redondeo de los valores negativos en la variable tiempo).
- Y, por lo menos al 89 % de los clientes les lleva de 0 a 90.72 minutos el tomar una decisión de compra.


Estas cantidades te pueden servir de referencia en futuras campañas publicitarias para medir la efectividad de estas.

Para terminar...

No olvides que el teorema de Chebyshev integra la media y la desviación estándar, considerando también la posible simetría o asimetría de los datos.

Reflexiona: ¿Qué tanto crees que llevar tu análisis al nivel de combinar distintas medidas resumen, como lo hace este teorema, puede darte una visión más completa y profunda de tu negocio?

Recuerda que la desviación estándar no es sólo un número: refleja la presencia de incertidumbre, riesgo, calidad y variación respecto a la media. Usar estas herramientas te permitirá **comprender mejor el comportamiento de tus datos y tomar decisiones más seguras y fundamentadas.**



Descarga este documento en la sección **"Archivos adjuntos"** de la plataforma.